Metodología — avance

III. METODOLOGÍA

La presente investigación se desarrolló bajo el marco estándar CRISP-DM (Cross-Industry Standard Process for Data Mining), que organiza el ciclo de vida analítico en fases secuenciales de comprensión de los datos, preparación, modelado, evaluación y despliegue. Sobre este marco se articularon la integración relacional de los microdatos, la definición de la variable objetivo con control de fuga de información, la selección de características, el tratamiento del desbalance de clases, el entrenamiento comparativo de algoritmos supervisados, la evaluación del desempeño, la interpretabilidad algorítmica, la implementación del sistema de soporte a la decisión y la evaluación de su pertinencia.

La Figura 1 resume el flujo metodológico completo y la correspondencia de cada etapa con las fases de CRISP-DM. Las subsecciones siguientes describen cada etapa en el mismo orden.

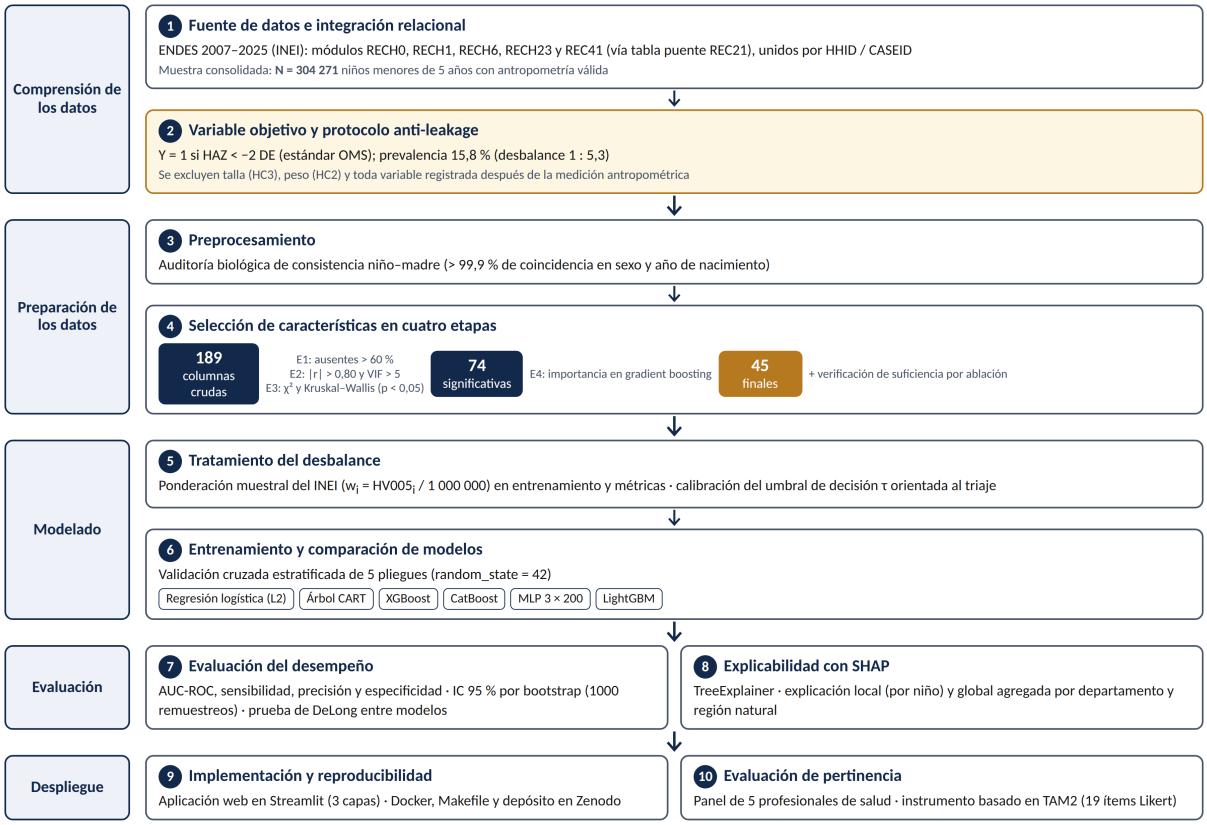


Figura 1: Flujo metodológico del estudio organizado según las fases de CRISP-DM.

A. Fuente de datos e integración relacional

El estudio utilizó los microdatos anuales de la Encuesta Demográfica y de Salud Familiar (ENDES), recolectados y publicados por el Instituto Nacional de Estadística e Informática (INEI) de Perú entre los años 2007 y 2025.

Para estructurar la unidad de análisis se diseñó un flujo de extracción e integración relacional que vinculó cinco módulos principales mediante las llaves compuestas HHID y CASEID (Figura 2). El módulo RECH0 proveyó los metadatos de la entrevista, RECH1 aportó las características demográficas de los integrantes del hogar, RECH6 suministró los indicadores antropométricos y de salud infantil, y RECH23 consolidó las

condiciones de vivienda, saneamiento y altitud geográfica, variable cuya relación con la concentración de hemoglobina en la población infantil peruana se encuentra documentada [1]. El módulo REC41 incorporó la historia obstétrica materna, los controles prenatales y el peso al nacer, vinculado de forma unívoca a través de la tabla relacional puente REC21. La muestra consolidada quedó conformada por 304,271 niños y niñas menores de cinco años que contaban con registros antropométricos válidos.

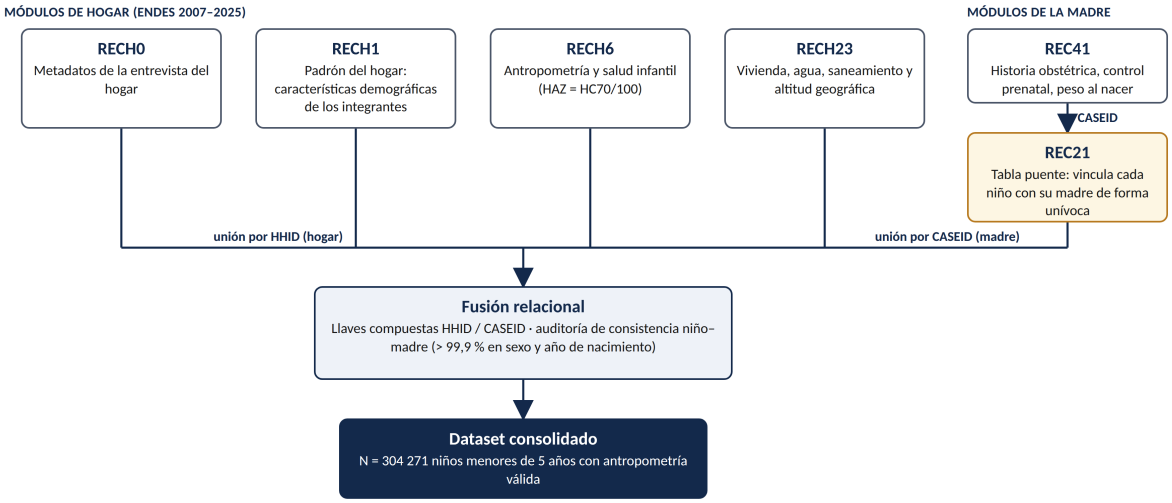


Figura 2: Integración relacional de los módulos de la ENDES 2007–2025 mediante las llaves HHID y CASEID.

B. Variable objetivo y protocolo anti-leakage

La variable dependiente es la desnutrición crónica infantil, categorizada de acuerdo con los estándares internacionales de crecimiento de la Organización Mundial de la Salud (OMS), criterio empleado de forma sistemática en el análisis de la desnutrición infantil peruana [2, 3]. Se definió como caso positivo ($Y = 1$) a todo infante cuyo puntaje Z de talla para la edad (HAZ = HC70/100) se situó por debajo de menos dos desviaciones estándar respecto a la mediana de referencia, y como caso control ($Y = 0$) en caso contrario, según la Ecuación (1). La prevalencia global en la serie histórica fue del 15.8%, lo que establece un ratio de desbalance de 1 a 5.3.

$$Y = \begin{cases} 1, & \text{si HAZ} < -2.00 \text{ DE} \\ 0, & \text{si HAZ} \geq -2.00 \text{ DE} \end{cases} \tag{1}$$

Para preservar la validez metodológica y evitar el sobreajuste espurio por fuga de datos (*data leakage*) [4], se excluyeron de las variables predictoras la talla directa en centímetros (HC3) y el peso crudo (HC2). Asimismo, se excluyó cualquier intervención terapéutica o diagnóstico clínico registrado con posterioridad a la medición antropométrica.

C. Preprocesamiento y selección de características

Antes del modelado se ejecutó una auditoría biológica de consistencia entre el registro infantil y el materno, con una coincidencia superior al 99.9% en sexo y año de nacimiento.

El espacio original compuesto por 189 columnas crudas fue depurado a través de un protocolo de selección cuantitativo en cuatro etapas sucesivas. En la primera etapa se descartaron los atributos con más del 60% de valores ausentes estructurales históricos. En la segunda etapa se redujo la redundancia dimensional eliminando variables colineales mediante correlación bivariada de Pearson y Spearman ($r > 0.80$) y factores de inflación de varianza (VIF > 5).

En la tercera etapa se aplicaron pruebas de hipótesis bivariadas: la prueba de independencia Chi-cuadrado para variables categóricas y la prueba no paramétrica de Kruskal–Wallis para continuas, reteniendo 74 factores estadísticamente significativos ($p < 0.05$). En la cuarta etapa se ejecutó una validación multivariada basada en la importancia algorítmica nativa de árboles de decisión con gradient boosting, seleccionando un conjunto final de 45 variables (Tabla 1).

Para verificar que la reducción dimensional no hubiese descartado señal predictiva relevante, se diseñó un estudio de ablación sobre las 33 columnas del conjunto preprocesado que no formaron parte de las 45 seleccionadas. Estas se ordenaron según su señal marginal respecto a la variable objetivo, cuantificada para

los atributos categóricos como la amplitud entre la tasa de prevalencia máxima y mínima observada entre categorías con soporte mínimo de 500 observaciones, y para los continuos mediante el estadístico $2 \cdot |\text{AUC} - 0.5|$. Las variables de mayor señal corresponden al bloque de agua, saneamiento e higiene y condiciones materiales de la vivienda, que la literatura reporta como determinante subyacente del retraso del crecimiento lineal [5, 6] y que estudios previos con datos DHS recuperan entre sus predictores principales [7].

Se contrastaron cuatro configuraciones del espacio de atributos (subconjunto seleccionado, ampliación con agua, saneamiento y vivienda, ampliación con atributos territoriales y ampliación conjunta), manteniendo constantes la partición, la ponderación muestral aplicada al entrenamiento y a las métricas, la semilla determinista y los hiperparámetros del clasificador, de modo que la única fuente de variación fuese la composición del espacio de atributos.

Tabla 1: Variables predictoras finales ($n = 45$).

Bloque	**Variables (código ENDES)**
Vivienda, agua y saneamiento	Tratamiento del agua (HV237, HV237A, HV237G); tiempo de desplazamiento a la fuente (HV204); uso compartido del servicio higiénico (HV225); ambiente separado para cocinar (HV242); número de habitaciones (HV216, SH71); aberturas de la vivienda (SH76B, SH76C, SH76D)
Características del niño	Nivel de hemoglobina

D. Tratamiento del desbalance de clases

Para reflejar la distribución demográfica del país y corregir el sesgo de sobremuestreo urbano inherente a la encuesta, se incorporó el factor de ponderación muestral del INEI, $w_i = \text{HV005}_i/1{,}000{,}000$, tanto en el entrenamiento como en el cálculo de las métricas. Adicionalmente, el umbral de decisión τ se calibró en lugar de usar el valor por defecto, con un criterio orientado al triaje preventivo que prioriza la cobertura de los casos de desnutrición.

E. Modelos de aprendizaje automático

El proceso de entrenamiento evaluó seis familias de algoritmos supervisados: Regresión Logística con regularización L2, Árbol de Decisión CART, XGBoost, CatBoost, Red Neuronal Perceptrón Multicapa (MLP 3×200) y LightGBM. La elección de los métodos de ensamble basados en árboles responde a la evidencia previa sobre datos DHS, donde estos superan de forma sistemática a los modelos lineales [7–9]. LightGBM, en particular, agrupa de forma nativa variables categóricas de alta cardinalidad por histogramas sin recurrir a la expansión dimensional del One-Hot Encoding [10].

Tabla 2: Configuración de los modelos evaluados.

Modelo	**Hiperparámetros**
Regresión Logística	Regularización L2
Árbol CART	—
XGBoost	—
CatBoost	—
MLP	3 capas ocultas de 200 neuronas
LightGBM	—
Todos	Semilla determinista `random_state = 42`

F. Estrategia de validación y métricas de evaluación

La partición y validación experimental se realizaron mediante validación cruzada estratificada de 5 pliegues (Stratified 5-Fold Cross-Validation), fijando una semilla determinista (`random_state = 42`). Las métricas se calcularon sobre las probabilidades fuera de pliegue (*out-of-fold*) de los 304,271 registros, siguiendo las recomendaciones de reporte de modelos predictivos en salud [11].

El desempeño se evaluó con el área bajo la curva ROC (AUC-ROC), la sensibilidad (Recall) y la precisión, ponderadas con el factor muestral w_i:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}, \qquad \text{Precisin} = \frac{VP}{VP + FP} \tag{2}$$

donde VP, FN y FP son los verdaderos positivos, falsos negativos y falsos positivos.

La confiabilidad de las estimaciones se certificó mediante remuestreo Bootstrap no paramétrico con 1,000 repeticiones sobre las probabilidades fuera de pliegue, con intervalos de confianza al 95%. La superioridad del modelo campeón frente a los algoritmos de referencia se contrastó con la prueba de DeLong sobre curvas ROC correlacionadas. Dado que el estadístico de DeLong se define sobre rangos y no admite ponderación muestral, este contraste se aplicó sobre la muestra sin expandir; la validez de la comparación se preserva porque todos los modelos se evalúan sobre los mismos individuos y el contraste recae sobre la diferencia entre curvas y no sobre el nivel absoluto del área.

G. Explicabilidad algorítmica con valores SHAP

Para dotar de transparencia al sistema y eliminar el carácter opaco del modelo de ensamble, se aplicó la teoría de juegos cooperativos mediante el algoritmo TreeExplainer del framework SHAP (SHapley Additive exPlanations) [12]. Este marco descompone la probabilidad predicha en la suma del valor base poblacional ϕ_0 más las contribuciones marginales individuales ϕ_j de cada una de las $M = 45$ variables predictoras:

$$f(x) = \phi_0 + \sum_{j=1}^{M} \phi_j(x) \tag{3}$$

A nivel local, el sistema descompone la predicción individual en factores de riesgo agravantes y condiciones protectoras. A nivel global y territorial, se agregaron los valores SHAP sobre una muestra representativa de 10,000 registros para construir mapas de riesgo y perfiles de determinantes diferenciados para los 25 departamentos y las tres regiones naturales del país.

H. Implementación, reproducibilidad y evaluación de pertinencia

La solución computacional se implementó como una aplicación web interactiva desarrollada en Streamlit, organizada bajo un patrón de tres capas. La capa de presentación contiene el módulo de visualización coroplética departamental con geometrías GeoJSON y el simulador de triaje individual con gráficos interactivos. La capa lógica integra el motor de inferencia entrenado con LightGBM, el calibrador dinámico de punto de corte y el generador de explicabilidad SHAP en tiempo de ejecución. La capa de datos gestiona el almacenamiento columnar en formato Parquet junto con los metadatos de configuración serializados en JSON.

La replicabilidad se garantizó según los principios FAIR mediante la modularización del código en el paquete Python `mnp/`, el aislamiento del entorno con Docker (`python:3.12-slim`), la automatización del flujo completo mediante Makefile y la publicación del dataset maestro y del modelo serializado en el repositorio abierto Zenodo.

La pertinencia de la herramienta se evaluó mediante un panel de cinco profesionales del ámbito sanitario —dos nutricionistas, un médico y dos enfermeros—, seleccionados bajo criterios de al menos diez años de experiencia asistencial y grado mínimo de maestría en salud pública o áreas afines. La evaluación se apoyó en el Modelo de Aceptación Tecnológica [13] en su extensión TAM2 [14], elegida aplicando el marco de decisión de Britto [15]: el estudio corresponde a un contexto organizacional de uso voluntario, en etapa de aceptación inicial y con un panel reducido que no admite modelos de alta complejidad. De TAM3 [16] se incorporó únicamente el constructo de percepción de control externo, para indagar si los datos que requiere el sistema están disponibles en la práctica asistencial; se omitieron los constructos de imagen y voluntariedad de TAM2, que no aplican a especialistas que evalúan la herramienta sin estar obligados a adoptarla.

Los ítems se adaptaron al contexto sanitario a partir de las escalas publicadas por Venkatesh y Davis [14, Apéndice 1], conservando por constructo solo los enunciados con contenido distinto, sin bajar de dos ítems (Tabla 3). El instrumento resultante consta de 19 afirmaciones en escala Likert de cinco puntos, una valoración global de 1 a 10 y cuatro preguntas abiertas; el ítem K2 consulta expresamente la disponibilidad del dato de hemoglobina, la única de las 45 variables que exige un procedimiento sobre el menor. Las respuestas se analizan de forma descriptiva mediante la mediana y el rango intercuartílico por constructo y el porcentaje de acuerdo por ítem, y un constructo se considera favorablemente valorado cuando su mediana es igual o superior a 4.

Tabla 3: Constructos e ítems del instrumento de evaluación de pertinencia.

Constructo	Modelo de origen	Ítems en la fuente	Ítems del instrumento
Relevancia para el trabajo	TAM2	2	2 (R1–R2)
Calidad del resultado	TAM2	2	2 (C1–C2)
Demostrabilidad del resultado	TAM2	4	2 (D1–D2)
Norma subjetiva	TAM2	2	2 (S1–S2)
Utilidad percibida	TAM	4	3 (U1–U3)
Facilidad de uso percibida	TAM	4	3 (F1–F3)
Intención de uso	TAM	2	2 (I1–I2)
Percepción de control externo	TAM3	—	3 (K1–K3)

References

[1] R. A. Accinelli and J. A. Leon-Abarca, "Age and altitude of residence determine anemia prevalence in Peruvian 6 to 35 months old children," *PLOS ONE*, vol. 15, no. 1, p. e0226846, 2020.

[2] M. Sobrino, C. Gutiérrez, A. J. Cunha, M. Dávila, and J. Alarcón, "Desnutrición infantil en menores de cinco años en Perú: tendencias y factores determinantes," *Revista Panamericana de Salud Pública*, vol. 35, no. 2, pp. 104–112, 2014.

[3] M. P. Santos, B. Turner, and M. P. Chaparro, "The double burden of malnutrition in Peru: an update with a focus on social inequities," *The American Journal of Clinical Nutrition*, vol. 113, no. 4, pp. 865–873, 2021.

[4] S. Kaufman, S. Rosset, and C. Perlich, "Leakage in data mining: formulation, detection, and avoidance," in *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 556–563, 2011.

[5] R. E. Black, C. G. Victora, S. P. Walker, Z. A. Bhutta, P. Christian, M. de Onis, M. Ezzati, S. Grantham-McGregor, J. Katz, R. Martorell, and R. Uauy, "Maternal and child undernutrition and overweight in low-income and middle-income countries," *The Lancet*, vol. 382, no. 9890, pp. 427–451, 2013.

[6] C. G. Victora, P. Christian, L. P. Vidaletti, G. Gatica-Domínguez, P. Menon, and R. E. Black, "Revisiting maternal and child undernutrition in low-income and middle-income countries: variable progress towards an unfinished agenda," *The Lancet*, vol. 397, no. 10282, pp. 1388–1399, 2021.

[7] F. H. Bitew, C. S. Sparks, and S. H. Nyarko, "Machine learning algorithms for predicting undernutrition among under-five children in Ethiopia," *Public Health Nutrition*, pp. 1–12, 2021.

[8] A. Talukder and B. Ahammed, "Machine learning algorithms for predicting malnutrition among under-five children in Bangladesh," *Nutrition*, vol. 78, p. 110861, 2020.

[9] O. N. Chilyabanyama, R. Chilengi, M. Simuyandi, C. C. Chisenga, M. Chirwa, K. Hamusonde, R. K. Saroj, N. T. Iqbal, and I. Ngaruye, "Performance of machine learning classifiers in classifying stunting among under-five children in Zambia," *Children*, vol. 9, no. 7, p. 1082, 2022.

[10] C. Bentéjac, A. Csörgő, and G. Martínez-Muñoz, "A comparative analysis of gradient boosting algorithms," *Artificial Intelligence Review*, vol. 54, no. 3, pp. 1937–1967, 2021.

[11] K. G. M. Moons, D. G. Altman, J. B. Reitsma, J. P. A. Ioannidis, P. Macaskill, E. W. Steyerberg, A. J. Vickers, D. F. Ransohoff, and G. S. Collins, "Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): explanation and elaboration," *Annals of Internal Medicine*, vol. 162, no. 1, pp. W1–W73, 2015.

[12] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017.

[13] F. D. Davis, "Perceived usefulness, perceived ease of use, and user acceptance of information technology," *MIS Quarterly*, vol. 13, no. 3, pp. 319–340, 1989.

[14] V. Venkatesh and F. D. Davis, "A theoretical extension of the technology acceptance model: four longitudinal field studies," *Management Science*, vol. 46, no. 2, pp. 186–204, 2000.

[15] N. P. Britto, "A decision framework for selecting technology acceptance and use models: TAM, TAM2, TAM3, UTAUT, and UTAUT2." arXiv preprint arXiv:2608.08333, 2026.

[16] V. Venkatesh and H. Bala, "Technology acceptance model 3 and a research agenda on interventions," *Decision Sciences*, vol. 39, no. 2, pp. 273–315, 2008.

[17] S. Ndagijimana, I. Kabano, E. Masabo, and J. M. Ntaganda, "Predicting stunting status among under-5 children in Rwanda using neural network model: evidence from 2020 Rwanda demographic and health survey," *F1000Research*, vol. 13, p. 128, 2025.

Anexo de trabajo: material trasladado a Resultados y Discusión

Este anexo no forma parte de la Metodología. Reúne lo que salió de tu borrador para que lo pegues en las secciones correspondientes.

Para Resultados

- **Modelo campeón:** LightGBM obtuvo el desempeño más alto, con un área bajo la curva ROC de 0.8295 y una sensibilidad (Recall) de 76.44% a umbral estándar.
- **Ablación:** el procedimiento identificó diez atributos con señal marginal elevada: material de las paredes (HV214, 40.9 puntos porcentuales), del piso (HV213, 39.4) y del techo (HV215, 36.2), fuente de agua (HV201, 34.1), departamento (HV024, 32.2), cloro residual (SH227, 30.2), combustible para cocinar (HV226, 26.3) y servicio higiénico (HV205, 22.7). Ninguno constituye fuga de información.
- **Configuraciones de ablación:** las cuatro configuraciones (45, 52, 48 y 55 atributos) obtuvieron AUC-ROC = 0.8295, Recall = 76.44%, Precisión = 36.36% y ΔAUC = +0.0000. Un clasificador solo con agua, saneamiento y vivienda alcanzó AUC-ROC = 0.6895, y la varianza explicada por el índice de riqueza se situó entre $\eta^2 = 0.038$ y $\eta^2 = 0.098$. El subconjunto de 45 ya representa el constructo de condiciones materiales del hogar a través de diecinueve atributos correlacionados.
- **Bootstrap:** AUC-ROC de 0.8294, IC 95% [0.8267, 0.8324]; sensibilidad de 76.43%, IC 95% [75.88%, 76.98%].
- **DeLong:** $p < 10^{-300}$ ($z = 62.32$ contra XGBoost y $z = 61.48$ contra Regresión Logística); AUC sin expandir de 0.8193, 0.7775 y 0.7767.
- **Umbral:** $\tau = 0.45$, cobertura de 80.5% con precisión asociada de 34.0%.

Para Discusión

- El AUC obtenido se sitúa en el rango de los trabajos previos de predicción de retraso del crecimiento con encuestas demográficas y de salud, en torno a 0.84 [17], pese a operar exclusivamente con variables de encuesta.
- La superioridad de los ensambles basados en árboles frente a los modelos lineales es coherente con la evidencia previa sobre datos DHS [7–9].