Hallazgos de validación del modelo

Registro de las comprobaciones hechas sobre el modelo campeón, con el procedimiento seguido y la lectura de cada resultado. Sirve como respaldo para responder preguntas del panel de expertos y como material para la sección de discusión del artículo.

1. Aporte de la hemoglobina (`HC56`)

Por qué se midió. De las 45 variables del modelo, `HC56` es la única que exige un procedimiento sobre el niño —una punción para el tamizaje de anemia—. El resto se obtiene por entrevista al hogar. Si su aporte fuera pequeño, el sistema podría operar en zonas donde ese tamizaje no está disponible.

Procedimiento. `mnp/evaluation/ablation_hemoglobina.py`. Se entrenan dos configuraciones bajo el protocolo del benchmark — `StratifiedKFold` de 5 pliegues, `random_state = 42`, ponderación `HV005` en entrenamiento y evaluación, mismos hiperparámetros— de modo que la única fuente de variación sea la ausencia de la variable. Sobre las probabilidades *out-of-fold* se remuestrea la diferencia de AUC 1,000 veces.

Resultado.

Configuración	AUC	Cobertura	Precisión
Con hemoglobina (45 variables)	0.8294	76.43%	36.36%
Sin hemoglobina (44 variables)	0.8281	76.30%	36.19%
Diferencia	**−0.0014**	−0.13 pts	−0.17 pts

Bootstrap de la diferencia: **−0.0014, IC 95% [−0.0019, −0.0009]**.

Lectura. El intervalo no cruza el cero, de modo que la diferencia es estadísticamente distinguible. Eso era previsible: con 304,271 registros, diferencias muy pequeñas alcanzan significación. Lo relevante es la magnitud: **trece casos menos detectados por cada diez mil niños evaluados**.

La conclusión defendible es que la hemoglobina **aporta, pero poco**. El sistema puede operar solo con datos de entrevista a un costo bajo, lo que amplía su aplicabilidad a contextos sin tamizaje rutinario.

> **Nota sobre una versión anterior.** Una primera corrida exploratoria, sin intervalos de confianza, llevó a describir la diferencia como «inapreciable». Al formalizar el experimento con bootstrap, esa caracterización resultó inexacta y se corrigió tanto aquí como en la presentación al panel.

2. Suficiencia del subconjunto de variables

Por qué se midió. Para descartar que la reducción de más de 180 variables a 45 hubiera dejado fuera señal predictiva relevante.

Procedimiento. `mnp/evaluation/feature_ablation.py`. Se ordenan las 33 columnas descartadas por su señal marginal frente al objetivo y se reincorporan las diez de mayor señal —material de paredes, piso y techo, fuente de agua, departamento, cloro residual, combustible de cocina y servicio higiénico— en tres configuraciones sucesivas.

Resultado. El AUC, la cobertura y la precisión permanecen invariables hasta la cuarta cifra decimal en las tres ampliaciones (0.8295 y 76.44% en todas).

Lectura. Las variables candidatas no aportan porque el subconjunto retenido **ya representa el mismo constructo** a través de diecinueve atributos correlacionados de vivienda, agua y saneamiento. Su exclusión fue una decisión correcta, no una omisión.

Un clasificador entrenado *solo* con el bloque de agua, saneamiento y vivienda alcanza AUC 0.6895, de modo que la señal existe; simplemente está ya capturada.

3. Estabilidad frente a la incorporación de un año nuevo

Por qué se midió. El INEI publicó la ENDES 2025 durante la ejecución del proyecto, y convenía comprobar si el modelo se sostenía al ampliar la serie de 18 a 19 años.

Resultado.

	18 años (2007–2024)	19 años (2007–2025)
Registros	285,284	304,271
AUC	0.8308	0.8295

	18 años (2007–2024)	19 años (2007–2025)
Cobertura	76.49%	76.44%
Variables	43	45

Lectura. El desplazamiento del AUC (−0.0013) queda dentro de la dispersión entre pliegues (0.8230–0.8353), de modo que el modelo es estable. LightGBM se mantiene como campeón y el orden del *benchmarking* no varía.

Dos variables nuevas — `HV219`, sexo del jefe del hogar, y `SH77F`, otro tipo de transporte— cruzaron el umbral de importancia con el año adicional, sin que ninguna de las 43 originales fuera descartada. Esto refuerza el resultado del punto 2: cuando una variable descartada tiene señal real, el propio criterio de importancia la recupera al haber más datos.

---

4. Confiabilidad estadística del modelo campeón

Procedimiento. `mnp/evaluation/bootstrap_validation.py`. Remuestreo no paramétrico de 1,000 repeticiones sobre las probabilidades *out-of-fold*, y prueba de DeLong sobre curvas ROC correlacionadas frente a los dos algoritmos de referencia.

Resultado.

Métrica	Estimación	IC 95%
AUC-ROC	0.8294	[0.8267, 0.8324]
Cobertura	76.43%	[75.88%, 76.98%]
Precisión	36.36%	[35.94%, 36.71%]

Prueba de DeLong: LightGBM supera a XGBoost ($z = 62.32$) y a Regresión Logística ($z = 61.48$), ambos con $p < 10^{-300}$.

Lectura. La amplitud de los intervalos es inferior a medio punto porcentual, lo que indica que las estimaciones no dependen del subconjunto de evaluación. La superioridad sobre los modelos de referencia no es atribuible al azar.

> **Precisión metodológica.** El estadístico de DeLong se define sobre rangos y no admite ponderación muestral, de modo que los AUC de ese contraste (0.8193, 0.7775 y 0.7767) van sin expandir por `HV005` y quedan sistemáticamente por debajo de los ponderados. La comparación sigue siendo válida porque los tres modelos se evalúan sobre los mismos individuos.

---

5. Calibración del umbral de decisión

Procedimiento. `mnp/evaluation/threshold_curve.py`. Barrido del punto de corte sobre probabilidades *out-of-fold*, con el mismo protocolo del benchmark.

Resultado. El valor mínimo que garantiza una cobertura ≥ 80% es **$\tau = 0.45$**, con cobertura 80.46% y precisión 34.04%.

Lectura. Los documentos del ciclo anterior consignaban $\tau \approx 0.35$ para esa meta. Ese valor produce en realidad 87.95% de cobertura y 29.36% de precisión: sobrepasa el objetivo y sacrifica precisión sin necesidad. La cifra fue corregida en la metodología y en el plan de validación.

---

6. Figuras disponibles para la presentación

Inventario de las 45 figuras que generan los scripts, con su aptitud para un panel clínico. Ruta base: `reports/figures/`.

Recomendadas

Figura	Ruta	Por qué
Evolución del desbalance de clases	`01_data_understanding/clean/01_eda_interim_rech6/09_*`	Muestra la caída de la desnutrición crónica del 32% en 2007 al 12% en 2025. Autoexplicativa, sin vocabulario técnico, y justifica de un vistazo por qué el problema sigue vigente pese a la mejora

Figura	Ruta	Por qué
Curva de acumulación clínica	`01_data_understanding/clean/01_eda_interim_rech6/11_*`	El Z-score cae entre los 15 y 22 meses de edad: es la ventana de los primeros 1000 días que el panel conoce bien. Requiere recortarla a un solo año y corregir el título, que aún dice 2019-2024
Distribución del Z-score	`01_data_understanding/clean/01_eda_interim_rech6/10_*`	Sitúa el umbral de –2 DE sobre la distribución real, y explica el criterio diagnóstico sin recurrir a la definición formal

Solo si hay preguntas técnicas

Figura	Ruta	Observación
Curvas ROC	`03_modeling/03_model_benchmarking_extended/01_*`	Estándar para comparar los seis algoritmos, pero exige explicar qué es una curva ROC. Reservar para el anexo
Mapa de calor SHAP por departamento	`03_modeling/03_model_explainability/02_*`	El contenido es el más valioso del proyecto —los factores cambian según el departamento— pero los ejes llevan nombres de variable ENDES (`HV271_Factor_de_puntuacion...`) y resulta ilegible para quien no conoce el diccionario. Conviene rehacerla con etiquetas en lenguaje natural y menos columnas

No recomendadas para esta sesión

Las figuras de auditoría de nulos, deriva de esquema y evolución de materiales de vivienda (`05_evolucion_de_las_excusas_de_no`, `15_variables_con_mayor_de_valores_nulos`, `03_evolucion_historica_del_material_de_techos`, entre otras) documentan el trabajo de preparación de datos. Son pertinentes para el artículo y para un jurado de ingeniería, pero no aportan al juicio de utilidad que se pide al panel clínico.

> **Preferible a cualquier figura:** la demostración en vivo del aplicativo. El panel valora la facilidad de uso, y para responder esa mitad del instrumento necesita haber visto la interfaz en funcionamiento.