Solicitud

SOLICITUD DE VALIDACIÓN POR JUICIO DE EXPERTOS

Proyecto: *Modelo Predictivo de Riesgo de Desnutrición Crónica Infantil en el Perú mediante Machine Learning*

Institución: Universidad Peruana Unión (UPeU) — Facultad de Ingeniería y Arquitectura, EP Ingeniería de Sistemas **Asignatura:** Investigación V (Ciclo X – 2026-II) · **Docente:** Mg. Nemias Saboya Rios **Equipo:** Abel Guevara Huasco · Verónica Vergara Rojas · Pamela Vallejos Cotrina

---

1. Objetivo

Predecir el **perfil de riesgo de desnutrición crónica infantil** en menores de 5 años a partir de variables sociodemográficas, del hogar y de salud materna recogidas por encuesta, con el fin de **orientar la focalización de recursos** en salud pública.

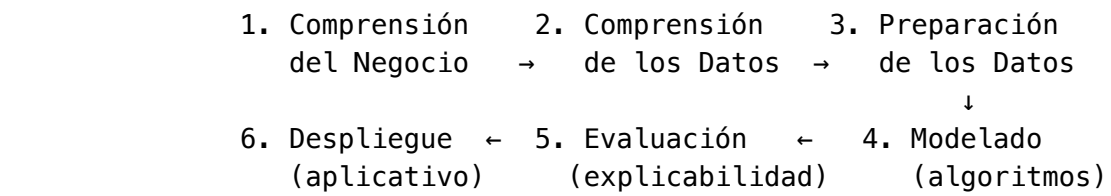
El sistema **no reemplaza el diagnóstico clínico ni la medición antropométrica**. Funciona como una herramienta de **triaje previo**: dado el perfil de un hogar, estima la probabilidad de que el niño presente desnutrición crónica, permitiendo priorizar a quién visitar primero cuando el presupuesto no alcanza para cubrir a toda la población.

Pregunta de investigación: ¿Puede un modelo de *Machine Learning* identificar, con datos de encuesta de hogar, qué niños tienen mayor riesgo de desnutrición crónica antes de que un agente de salud llegue al domicilio?

---

2. Método

Se siguió **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), estándar de la industria para proyectos de ciencia de datos, organizado en seis fases:



Aspecto	Definición
Fuente	ENDES — INEI (Encuesta Demográfica y de Salud Familiar), datos públicos
Periodo	2007 – 2025 (19 años)
Muestra	**304,271 niños** menores de 5 años con antropometría válida
Variable objetivo	Desnutrición crónica: Z-score Talla/Edad (`HC70`) < –2 DE, estándar OMS / KPI 4 del INEI
Prevalencia	15.8%
Tipo de problema	Clasificación binaria supervisada
Validación	Validación cruzada estratificada 5-*fold* con ponderación muestral del INEI (`HV005`)

Decisión metodológica central: se **excluyeron deliberadamente el peso y la talla directos del niño** (`HC2`, `HC3`) y los Z-scores derivados. Si el modelo conociera la talla, el diagnóstico sería trivial y no habría predicción. El modelo aprende únicamente de variables *no obvias* —condiciones del hogar, historia materna y entorno— que la encuesta puede recoger sin medir al niño.

Resultados actuales: LightGBM resultó el algoritmo campeón entre seis evaluados, con **AUC-ROC 0.8294** (IC 95%: 0.8267 – 0.8324) y **sensibilidad 76.43%** (IC 95%: 75.88% – 76.98%), verificados mediante *bootstrap* de 1,000 repeticiones. El umbral de decisión es ajustable: elevando la sensibilidad a ≥ 80% el sistema detecta más casos reales a costa de más falsos positivos, criterio deliberado en triaje preventivo, donde no detectar a un niño desnutrido es más costoso que una visita de verificación innecesaria.

---

3. Variables que intervienen (45)

Estas son las variables que el modelo utiliza actualmente, agrupadas por dominio. **Son las que solicitamos encontrar en cualquier conjunto de datos externo con el que se desee contrastar el sistema.**

A. Niño (4)

Código ENDES	Variable
`HC1`	Edad en meses
`HC27`	Sexo
`HC56`	Hemoglobina ajustada por altitud
`HC63`	Intervalo respecto al nacimiento anterior

B. Salud materna, embarazo y lactancia (13)

Código	Variable
M13	Mes de gestación del primer control prenatal
M14	Número de visitas prenatales
m15	Lugar del parto
M17	Parto por cesárea
M18	Tamaño del niño al nacer
m19	Peso al nacer (kg)
M4	Duración de la lactancia
m34	Horas hasta el inicio de la lactancia
M46	Días que tomó hierro en el embarazo
M54	Vitamina A en los primeros 2 meses post parto
M55G	Fórmula para bebés en los primeros 3 días
M60	Antiparasitarios durante el embarazo
HC62	Año más alto de educación de la madre

C. Hogar y nivel socioeconómico (7)

Código	Variable
HV271	Índice de riqueza del hogar
HV012	Miembros habituales del hogar
HV014	Niños menores de 5 años en el hogar
HV219	Sexo del jefe del hogar
HV220	Edad del jefe del hogar
HV102	Residente habitual
HV025	Área de residencia (urbano / rural)

D. Agua, saneamiento e higiene — WASH (10)

Código	Variable
HV204	Tiempo de viaje a la fuente de agua
HV225	Comparte servicio higiénico
HV234	Prueba de yodo en la sal
HV237	Tratamiento del agua
HV237A	Tratamiento del agua: hervir
HV237G	Consumo de agua embotellada
SH42	Disponibilidad de agua todo el día
SH48	Conserva agua
SH49 / SH50	Tipo de recipiente y si lo usa con tapa

E. Vivienda y entorno (11)

Código	Variable
`HV040`	Altitud del conglomerado (msnm)
`HV216`	Habitaciones para dormir
`SH71`	Número de habitaciones del hogar
`HV240`	Tiene chimenea o campana
`HV242`	Cuarto separado para cocinar
`SH63`	Otro tipo de combustible para cocinar
`SH70`	Fuente de luz
`SH76B` / `SH76C` / `SH76D`	Ventanas con cristal / de madera / con malla
`SH77F`	Otro tipo de transporte

> **Nota:** el conjunto es ampliable. El *dataset* original contiene más de 180 variables, de las cuales se retuvieron 45 por criterios estadísticos. Si los especialistas consideran relevante alguna dimensión no cubierta —consumo dietético, morbilidad reciente, vacunación, antropometría materna— puede incorporarse siempre que exista en la fuente de datos.

3.bis. Especificación de campos

Esta tabla define **cómo debe venir codificada cada variable** en un conjunto de datos externo. El modelo compara valores de forma literal: una categoría escrita de otra manera (`"URBANO"` en lugar de `"Urbano"`, o `1/0` en lugar de `"Si"/"No"`) no produce un error visible, sino una predicción degradada en silencio. Por eso el formato importa tanto como la variable misma.

Convenciones - *Categórica*: texto, exactamente uno de los valores listados (sensible a mayúsculas y tildes). - *Código*: número entero que representa una categoría, **no una cantidad**. - *Numérica*: magnitud continua o discreta, en la unidad indicada. - Un campo ausente debe dejarse **vacío**, nunca rellenarse con 0, 999 o “NA”: el modelo maneja valores faltantes de forma nativa y cada variable tolera el porcentaje de vacíos que se indica.

Niño

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HC1`	Numérica	0 – 59	meses	0.0
`HC27`	Categórica	`Hombre` / `Mujer`	—	0.0
`HC56`	Numérica	4 – 20 (hemoglobina ajustada)	g/dL	9.6
`HC63`	Numérica	7 – 388	meses desde el parto anterior	36.3

Salud materna, embarazo y lactancia

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
M13	Código	0 – 9	mes de gestación del 1.er control	19.7
M14	Numérica	0 – 20	número de visitas	18.6
m15	Categórica	Institucional / Domiciliario	—	6.6
M17	Código	1 = cesárea, 0 = no	—	5.8
M18	Código	1 = muy grande … 5 = muy pequeño	—	5.8
m19	Numérica	0.5 – 6.0	kilogramos (decimal)	10.6
M4	Numérica	0 – 59	meses de lactancia	5.8
m34	Numérica	0 – 2352	horas hasta iniciar lactancia	6.2
M46	Numérica	0 – 364	días que tomó hierro	18.7
M54	Código	1 = sí, 0 = no	vitamina A post parto	19.7
M55G	Código	1 = sí, 0 = no	fórmula en los 3 primeros días	6.8
M60	Código	1 = sí, 0 = no	antiparasitarios en el embarazo	19.9
HC62	Código	0 – 9	año más alto de educación materna	4.8

Hogar y nivel socioeconómico

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV271	Numérica	−215987 a 205316	índice de riqueza (escala INEI $\times 10^5$)	0.8
HV012	Numérica	0 – 25	personas	0.0

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV014	Código	0 – 10	niños menores de 5 años	0.0
HV219	Categórica	Masculino / Femenino	sexo del jefe del hogar	0.0
HV220	Numérica	12 – 97	años	0.0
HV102	Categórica	Sí / No	**con tilde**	2.4
HV025	Categórica	Urbano / Rural	—	0.0

Agua, saneamiento e higiene (WASH)

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV204	Numérica	0 – 600	minutos hasta la fuente	0.1
HV225	Categórica	Si / No	**sin tilde**	10.8
HV234	Código	0, 7, 15, 30, 994, 995	prueba de yodo en sal	4.8
HV237	Categórica	Si / No	**sin tilde**	0.0
HV237A	Categórica	Si / No	**sin tilde**	0.0
HV237G	Categórica	Si / No	**sin tilde**	8.1
SH42	Categórica	Sí / No	**con tilde**	20.4
SH48	Categórica	Sí / No	**con tilde**	15.8
SH49	Código	0 – 8, 96, 98	tipo de recipiente	20.4
SH50	Código	0 – 8	lo usa con tapa	19.3

Vivienda y entorno

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV040	Numérica	0 – 5053	metros sobre el nivel del mar	0.0
HV216	Numérica	0 – 14	habitaciones para dormir	0.0
HV240	Código	0, 1, 2	tiene chimenea o campana	55.9
HV242	Categórica	Si / No	**sin tilde**	9.3
SH63	Categórica	Si / No	**sin tilde**	2.1
SH70	Código	1 – 6, 96, 99	fuente de luz	1.6
SH71	Numérica	1 – 30	habitaciones del hogar	0.0

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
SH76B	Categórica	Si / No	ventanas con cristal	16.2
SH76C	Categórica	Si / No	ventanas de madera	16.2
SH76D	Categórica	Si / No	ventanas con malla	16.2
SH77F	Categórica	Si / No	otro tipo de transporte	0.0

> **Advertencia sobre la codificación heredada.** Las tres irregularidades que siguen provienen de la propia ENDES y se conservaron para no alterar la fuente; se señalan aquí porque condicionan el formato de entrega:
>
> 1. **`Si` frente a `Sí`.** Unas variables llevan tilde y otras no, según el módulo de origen. La tabla indica cuál corresponde en cada caso y la distinción debe respetarse.
> 2. **Binarias en dos formatos.** `M17`, `M54`, `M55G` y `M60` se codifican `1`/`0`, mientras que el resto de las dicotómicas usan texto `Si`/`No`.
> 3. **Códigos especiales en campos numéricos.** `HV234` (994, 995), `SH49` (96, 98) y `SH70` (96, 99) reservan esos valores para *otro* o *no sabe*. No representan magnitudes y deben transcribirse tal cual, sin convertirlos ni sustituirlos por promedios.
>
> Si el conjunto de datos externo emplea otra codificación, basta con entregarlo acompañado de su diccionario de valores: el equipo se encarga de la homologación.

---

4. Qué esperamos de esta validación

Solicitamos la participación de **cinco especialistas** en nutrición, salud pública, epidemiología o enfermería, idealmente con representación territorial (**2 de costa, 2 de sierra, 1 de selva**), para dos procesos complementarios:

4.1 Pertinencia

Valoración de la **utilidad percibida** del sistema mediante un instrumento estructurado que el especialista completará tras una demostración del aplicativo. Se evalúa si la herramienta resulta útil, comprensible y aplicable en la práctica real de focalización sanitaria, y qué limitaciones o variables faltantes identifica desde su experiencia profesional.

Modalidad: sesión virtual, coordinada según disponibilidad. El equipo provee el protocolo, conduce la demostración y registra la sesión.

4.2 Replicabilidad

Contraste del modelo frente a **datos externos** distintos de la ENDES. El procedimiento consiste en que el especialista aporte registros de su ámbito —incluyendo casos con y sin desnutrición diagnosticada—, el sistema emita su estimación de riesgo, y se compare con el diagnóstico clínico conocido.

Esto permite medir si el modelo mantiene su desempeño en una realidad distinta de aquella con la que fue entrenado. Se requieren **datos crudos** (no reportes agregados), con las variables listadas en la sección 3.

---

5. Consideraciones éticas

Los datos con los que se construyó el modelo son de **acceso público y libre** (portal de microdatos del INEI), por lo que su tratamiento no requirió aprobación de comité de ética.

Para la fase de validación con datos institucionales, el equipo se compromete a tramitar los permisos formales correspondientes y a someter el protocolo a comité de ética cuando la institución lo exija. Los datos que se reciban se usarán exclusivamente con fines de validación técnica, de forma anonimizada, y no serán publicados ni compartidos con terceros.

---

6. Contribución esperada para los participantes

Los especialistas que participen serán reconocidos en el artículo científico resultante. Asimismo, el equipo queda disponible para integrarse como soporte técnico en investigaciones posteriores que deseen aplicar el modelo en estudios de campo, intervención o gestión sanitaria.

Contacto: equipo de investigación — EP Ingeniería de Sistemas, Universidad Peruana Unión.