SOLICITUD DE VALIDACIÓN POR JUICIO DE EXPERTOS

Proyecto: *Modelo Predictivo de Riesgo de Desnutrición Crónica Infantil en el Perú mediante Machine Learning*

Institución: Universidad Peruana Unión (UPeU) — Facultad de Ingeniería y Arquitectura, EP Ingeniería de Sistemas
Asignatura: Investigación V (Ciclo X – 2026-II) · **Docente:** Mg. Nemias Saboya Rios **Equipo:** Abel Guevara Huasco · Verónica Vergara Rojas · Pamela Vallejos Cotrina

---

1. Objetivo

Predecir el **perfil de riesgo de desnutrición crónica infantil** en menores de 5 años a partir de variables sociodemográficas, del hogar y de salud materna recogidas por encuesta, con el fin de **orientar la focalización de recursos** en salud pública.

El sistema **no reemplaza el diagnóstico clínico ni la medición antropométrica**. Funciona como una herramienta de **triaje previo**: dado el perfil de un hogar, estima la probabilidad de que el niño presente desnutrición crónica, permitiendo priorizar a quién visitar primero cuando el presupuesto no alcanza para cubrir a toda la población.

Pregunta de investigación: ¿Puede un modelo de *Machine Learning* identificar, con datos de encuesta de hogar, qué niños tienen mayor riesgo de desnutrición crónica antes de que un agente de salud llegue al domicilio?

---

2. Método

Se siguió **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), estándar de la industria para proyectos de ciencia de datos, organizado en seis fases:

```
1. Comprensión    2. Comprensión    3. Preparación
   del Negocio   →   de los Datos  →   de los Datos
                                            ↓
6. Despliegue  ←  5. Evaluación   ←   4. Modelado
   (aplicativo)     (explicabilidad)     (algoritmos)
```

Aspecto	Definición
Fuente	ENDES — INEI (Encuesta Demográfica y de Salud Familiar), datos públicos
Periodo	2007 – 2025 (19 años)
Muestra	**304,271 niños** menores de 5 años con antropometría válida
Variable objetivo	Desnutrición crónica: Z-score Talla/Edad (`HC70`) < –2 DE, estándar OMS / KPI 4 del INEI
Prevalencia	15.8%
Tipo de problema	Clasificación binaria supervisada
Validación	Validación cruzada estratificada 5-*fold* con ponderación muestral del INEI (`HV005`)

Decisión metodológica central: se **excluyeron deliberadamente el peso y la talla directos del niño** (`HC2`, `HC3`) y los Z-scores derivados, siguiendo el criterio de prevención de fuga de información (Kaufman et al., 2011). Si el modelo conociera la talla, el diagnóstico sería trivial y no habría predicción. El modelo aprende únicamente de variables *no obvias* — condiciones del hogar, historia materna y entorno— que la encuesta puede recoger sin medir al niño.

Resultados actuales: LightGBM resultó el algoritmo campeón entre seis evaluados, con **AUC-ROC 0.8294** (IC 95%: 0.8267 – 0.8324) y **sensibilidad 76.43%** (IC 95%: 75.88% – 76.98%), verificados mediante *bootstrap* de 1,000 repeticiones. El umbral de decisión es ajustable: elevando la sensibilidad a ≥ 80% el sistema detecta más casos reales a costa de más falsos positivos, criterio deliberado en triaje preventivo, donde no detectar a un niño desnutrido es más costoso que una visita de verificación innecesaria.

---

3. Variables que intervienen (45)

Esta tabla define **cómo debe venir codificada cada variable** en un conjunto de datos externo. El modelo compara valores de forma literal: una categoría escrita de otra manera (`"URBANO"` en lugar de `"Urbano"`, o `1/0` en lugar de `"Si"/"No"`) no produce un error visible, sino una predicción degradada en silencio. Por eso el formato importa tanto como la variable misma.

Convenciones

- *Categórica nominal*: texto, exactamente uno de los valores listados. No hay orden entre ellos.
- *Categórica ordinal*: texto, con orden implícito (de mayor a menor, según se lista).
- *Binaria*: texto, `Sí` o `No`.
- *Numérica*: magnitud real, en la unidad indicada. Aquí el número **sí** representa una cantidad.
- Un campo ausente debe dejarse **vacío**, nunca rellenarse con 0, 999 o “NA”: el modelo maneja valores faltantes de forma nativa y cada variable tolera el porcentaje de vacíos que se indica.

Las categorías se entregan **en texto, no en código numérico**. El `1` de una variable nominal no es una cantidad sino una etiqueta arbitraria, y su significado cambia entre ediciones de la encuesta: es preferible escribir `Electricidad` antes que `1`. Si el sistema de origen almacena códigos, basta con adjuntar su diccionario de valores.

Niño

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HC1`	Numérica	0 – 59	meses	0.0
`HC27`	Categórica nominal	`Hombre` / `Mujer`	sexo del niño	0.0
`HC56`	Numérica	4 – 20 (hemoglobina ajustada)	g/dL	9.6
`HC63`	Numérica	7 – 388	meses desde el parto anterior	36.3

Salud materna, embarazo y lactancia

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`M13`	Numérica	0 – 9	mes de gestación del 1.er control	19.7
`M14`	Numérica	0 – 20	número de visitas	18.6
`m15`	Categórica nominal	`Institucional` / `Domiciliario`	lugar del parto	6.6
`M17`	Binaria	`Sí` / `No`	¿el parto fue por cesárea?	5.8
`M18`	Categórica ordinal	`Muy grande` / `Grande` / `Mediano (normal)` / `Pequeño` / `Muy pequeño`	tamaño percibido al nacer	5.8
`m19`	Numérica	0.5 – 6.0	kilogramos (decimal)	10.6
`M4`	Numérica	0 – 59	meses de lactancia	5.8
`m34`	Numérica	0 – 2352	horas hasta iniciar lactancia	6.2
`M46`	Numérica	0 – 364	días que tomó hierro	18.7
`M54`	Binaria	`Sí` / `No`	vitamina A en los 2 meses post parto	19.7
`M55G`	Binaria	`Sí` / `No`	fórmula en los 3 primeros días	6.8
`M60`	Binaria	`Sí` / `No`	antiparasitarios durante el embarazo	19.9

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HC62`	Numérica	0 – 9	años de educación aprobados por la madre	4.8

Hogar y nivel socioeconómico

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HV271`	Numérica	−215987 a 205316	índice de riqueza (escala INEI $\times 10^5$)	0.8
`HV012`	Numérica	0 – 25	personas	0.0
`HV014`	Numérica	0 – 10	niños menores de 5 años en el hogar	0.0
`HV219`	Categórica nominal	`Masculino` / `Femenino`	sexo del jefe del hogar	0.0
`HV220`	Numérica	12 – 97	años	0.0
`HV102`	Binaria	`Sí` / `No`	residente habitual del hogar	2.4
`HV025`	Categórica nominal	`Urbano` / `Rural`	área de residencia	0.0

Agua, saneamiento e higiene (WASH)

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HV204`	Numérica	0 – 600	minutos hasta la fuente	0.1
`HV225`	Binaria	`Sí` / `No`	¿comparte servicio higiénico?	10.8
`HV234`	Numérica	0, 7, 15, 30	yodo en sal (ppm por colorimetría)	4.8
`HV237`	Binaria	`Sí` / `No`	¿trata el agua?	0.0
`HV237A`	Binaria	`Sí` / `No`	¿hierve el agua?	0.0
`HV237G`	Binaria	`Sí` / `No`	¿consume agua embotellada?	8.1
`SH42`	Binaria	`Sí` / `No`	¿dispone de agua todo el día?	20.4
`SH48`	Binaria	`Sí` / `No`	¿conserva agua?	15.8
`SH49`	Categórica nominal	`Olla, tetera` / `Balde` / `Jarra` / `Bidón` / `Otro`	recipiente donde conserva el agua	20.4
`SH50`	Binaria	`Sí` / `No`	¿usa el recipiente con tapa?	19.3

Vivienda y entorno

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HV040`	Numérica	0 – 5053	metros sobre el nivel del mar	0.0
`HV216`	Numérica	0 – 14	habitaciones para dormir	0.0
`HV240`	Categórica nominal	`Ni chimenea ni campana` / `Tubo de lámpara` / `Capucha`	extracción de humo en la cocina	55.9
`HV242`	Binaria	`Sí` / `No`	¿cuarto separado para cocinar?	9.3

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
SH63	Binaria	Sí / No	¿usa otro combustible para cocinar?	2.1
SH70	Categórica nominal	Electricidad / GLP / Gas natural / Kerosene / Velas / Batería / Otro	tipo de alumbrado	1.6
SH71	Numérica	1 – 30	habitaciones del hogar	0.0
SH76B	Binaria	Sí / No	ventanas con cristal	16.2
SH76C	Binaria	Sí / No	ventanas de madera	16.2
SH76D	Binaria	Sí / No	ventanas con malla	16.2
SH77F	Binaria	Sí / No	otro tipo de transporte	0.0

4. Variables adicionales deseables

Las 45 variables anteriores son las que el modelo **usa hoy** y constituyen el mínimo necesario para contrastarlo. Las que siguen **no están en el modelo actual** y se solicitan porque la literatura epidemiológica las identifica como determinantes de la desnutrición crónica que la ENDES no permite cubrir con suficiente completitud.

Su inclusión es **opcional**: el sistema funciona sin ellas. Pero cada dimensión que el conjunto de datos externo pueda aportar abre la posibilidad de una versión mejorada del modelo, y su ausencia es hoy una limitación declarada del estudio.

El marco de referencia es el **modelo conceptual de UNICEF** sobre desnutrición infantil, que ordena las causas en tres niveles y que la serie de nutrición materno-infantil de *The Lancet* sistematiza (Black et al., 2013; Victora et al., 2021). El modelo actual cubre bien los niveles básico y subyacente —pobreza, educación, agua y saneamiento, vivienda— pero tiene un vacío en el **nivel inmediato**, que es precisamente donde actúa la intervención nutricional.

Prioridad alta — nivel inmediato (el vacío principal)

Dimensión	Campo sugerido	Por qué importa
Morbilidad reciente	Episodios de diarrea en las últimas 2 semanas (sí/no)	Vía infecciosa hacia la malabsorción de nutrientes
Morbilidad reciente	Infección respiratoria aguda en las últimas 2 semanas (sí/no)	Impacto directo sobre el estado nutricional
Ingesta	Diversidad dietética mínima (número de grupos de alimentos en 24 h)	Indicador OMS de calidad de la alimentación
Ingesta	Frecuencia mínima de comidas según edad	Complemento del anterior
Suplementación	Recibe micronutrientes o hierro (sí/no, frecuencia)	Intervención directa y modificable

Prioridad media — estado nutricional materno y servicios

Dimensión	Campo sugerido	Por qué importa
Antropometría materna	Talla de la madre (cm)	Predictor consistente de retraso del crecimiento intergeneracional; resultó la variable más influyente en un modelo equivalente sobre datos DHS (Ndagijimana et al., 2025)
Antropometría materna	Peso / IMC de la madre	Estado nutricional del hogar
Servicios de salud	Controles CRED al día (sí/no, número)	Seguimiento del crecimiento en el sistema peruano
Servicios de salud	Esquema de vacunación completo para la edad (sí/no)	*Proxy* de acceso efectivo a servicios

Prioridad media — contexto social

Dimensión	Campo sugerido	Por qué importa
Etnicidad	Lengua materna de la madre	Marcador de exclusión estructural especialmente relevante en el Perú
Seguridad alimentaria	Escala de inseguridad alimentaria del hogar (ELCSA o similar)	Acceso efectivo a alimentos, no solo capacidad económica
Cuidado	Situación laboral de la madre / cuidador principal	Tiempo disponible para prácticas de cuidado
Programas sociales	Beneficiario de Juntos, Cuna Más, Qali Warma (sí/no)	Permite evaluar cobertura frente a necesidad

5. Qué esperamos de esta validación

Solicitamos la participación de **cinco especialistas** en nutrición, salud pública, epidemiología o enfermería, idealmente con representación territorial (**2 de costa, 2 de sierra, 1 de selva**), para dos procesos complementarios:

5.1 Pertinencia

Valoración de la **utilidad percibida** del sistema mediante un instrumento estructurado que el especialista completará tras una demostración del aplicativo. Se evalúa si la herramienta resulta útil, comprensible y aplicable en la práctica real de focalización sanitaria, y qué limitaciones o variables faltantes identifica desde su experiencia profesional.

Modalidad: sesión virtual, coordinada según disponibilidad. El equipo provee el protocolo, conduce la demostración y registra la sesión.

5.2 Replicabilidad

Contraste del modelo frente a **datos externos** distintos de la ENDES. El procedimiento consiste en que el especialista aporte registros de su ámbito —incluyendo casos con y sin desnutrición diagnosticada—, el sistema emita su estimación de riesgo, y se compare con el diagnóstico clínico conocido.

Esto permite medir si el modelo mantiene su desempeño en una realidad distinta de aquella con la que fue entrenado. Se requieren **datos crudos** (no reportes agregados), con las variables listadas en la sección 3.

6. Consideraciones éticas

Los datos con los que se construyó el modelo son de **acceso público y libre** (portal de microdatos del INEI), por lo que su tratamiento no requirió aprobación de comité de ética.

Para la fase de validación con datos institucionales, el equipo se compromete a tramitar los permisos formales correspondientes y a someter el protocolo a comité de ética cuando la institución lo exija. Los datos que se reciban se usarán exclusivamente con fines de validación técnica, de forma anonimizada, y no serán publicados ni compartidos con terceros.

7. Contribución esperada para los participantes

Los especialistas que participen serán reconocidos en el artículo científico resultante. Asimismo, el equipo queda disponible para integrarse como soporte técnico en investigaciones posteriores que deseen aplicar el modelo en estudios de campo, intervención o gestión sanitaria.

Contacto: equipo de investigación — EP Ingeniería de Sistemas, Universidad Peruana Unión.

Referencias citadas

- Black, R. E., Victora, C. G., Walker, S. P., *et al.* (2013). Maternal and child undernutrition and overweight in low-income and middle-income countries. *The Lancet*, 382(9890), 427–451.

- Kaufman, S., Rosset, S., & Perlich, C. (2011). Leakage in data mining: formulation, detection, and avoidance. *Proceedings of the 17th ACM SIGKDD*, 556–563.
- Ndagijimana, S., Kabano, I., Masabo, E., & Ntaganda, J. M. (2025). Predicting stunting status among under-5 children in Rwanda using neural network model. *F1000Research*, 13, 128.
- Victora, C. G., Christian, P., Vidaletti, L. P., *et al.* (2021). Revisiting maternal and child undernutrition in low-income and middle-income countries. *The Lancet*, 397(10282), 1388–1399.