Solicitud

SOLICITUD DE VALIDACIÓN POR JUICIO DE EXPERTOS

Proyecto: *Modelo Predictivo de Riesgo de Desnutrición Crónica Infantil en el Perú mediante Machine Learning*

Institución: Universidad Peruana Unión (UPeU) — Facultad de Ingeniería y Arquitectura, EP Ingeniería de Sistemas **Asignatura:** Investigación V (Ciclo X – 2026-II) · **Docente:** Mg. Nemias Saboya Rios **Equipo:** Abel Guevara Huasco · Verónica Vergara Rojas · Pamela Vallejos Cotrina

---

1. Objetivo

Predecir el **perfil de riesgo de desnutrición crónica infantil** en menores de 5 años a partir de variables sociodemográficas, del hogar y de salud materna recogidas por encuesta, con el fin de **orientar la focalización de recursos** en salud pública.

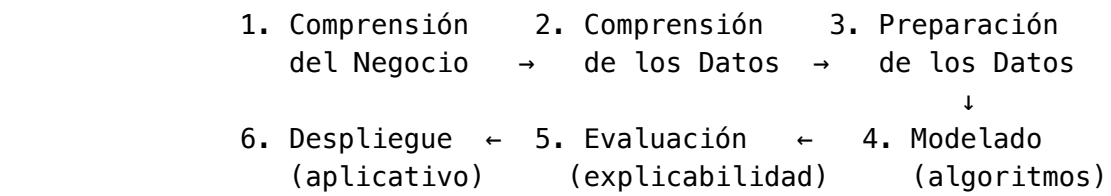
El sistema **no reemplaza el diagnóstico clínico ni la medición antropométrica**. Funciona como una herramienta de **triaje previo**: dado el perfil de un hogar, estima la probabilidad de que el niño presente desnutrición crónica, permitiendo priorizar a quién visitar primero cuando el presupuesto no alcanza para cubrir a toda la población.

Pregunta de investigación: ¿Puede un modelo de *Machine Learning* identificar, con datos de encuesta de hogar, qué niños tienen mayor riesgo de desnutrición crónica antes de que un agente de salud llegue al domicilio?

---

2. Método

Se siguió **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), estándar de la industria para proyectos de ciencia de datos, organizado en seis fases:



Aspecto	Definición
Fuente	ENDES — INEI (Encuesta Demográfica y de Salud Familiar), datos públicos
Periodo	2007 – 2025 (19 años)
Muestra	**304,271 niños** menores de 5 años con antropometría válida
Variable objetivo	Desnutrición crónica: Z-score Talla/Edad (`HC70`) < –2 DE, estándar OMS / KPI 4 del INEI
Prevalencia	15.8%
Tipo de problema	Clasificación binaria supervisada
Validación	Validación cruzada estratificada 5-*fold* con ponderación muestral del INEI (`HV005`)

Decisión metodológica central: se **excluyeron deliberadamente el peso y la talla directos del niño** (`HC2`, `HC3`) y los Z-scores derivados, siguiendo el criterio de prevención de fuga de información (Kaufman et al., 2011). Si el modelo conociera la talla, el diagnóstico sería trivial y no habría predicción. El modelo aprende únicamente de variables *no obvias* —condiciones del hogar, historia materna y entorno— que la encuesta puede recoger sin medir al niño.

Resultados actuales: LightGBM resultó el algoritmo campeón entre seis evaluados, con **AUC-ROC 0.8294** (IC 95%: 0.8267 – 0.8324) y **sensibilidad 76.43%** (IC 95%: 75.88% – 76.98%), verificados mediante *bootstrap* de 1,000 repeticiones. El umbral de decisión es ajustable: elevando la sensibilidad a ≥ 80% el sistema detecta más casos reales a costa de más falsos positivos, criterio deliberado en triaje preventivo, donde no detectar a un niño desnutrido es más costoso que una visita de verificación innecesaria.

---

3. Variables que intervienen (45)

Estas son las variables que el modelo utiliza actualmente, agrupadas por dominio. **Son las que solicitamos encontrar en cualquier conjunto de datos externo con el que se desee contrastar el sistema.**

A. Niño (4)

Código ENDES	Variable
`HC1`	Edad en meses
`HC27`	Sexo
`HC56`	Hemoglobina ajustada por altitud
`HC63`	Intervalo respecto al nacimiento anterior

B. Salud materna, embarazo y lactancia (13)

Código	Variable
M13	Mes de gestación del primer control prenatal
M14	Número de visitas prenatales
m15	Lugar del parto
M17	Parto por cesárea
M18	Tamaño del niño al nacer
m19	Peso al nacer (kg)
M4	Duración de la lactancia
m34	Horas hasta el inicio de la lactancia
M46	Días que tomó hierro en el embarazo
M54	Vitamina A en los primeros 2 meses post parto
M55G	Fórmula para bebés en los primeros 3 días
M60	Antiparasitarios durante el embarazo
HC62	Año más alto de educación de la madre

C. Hogar y nivel socioeconómico (7)

Código	Variable
HV271	Índice de riqueza del hogar
HV012	Miembros habituales del hogar
HV014	Niños menores de 5 años en el hogar
HV219	Sexo del jefe del hogar
HV220	Edad del jefe del hogar
HV102	Residente habitual
HV025	Área de residencia (urbano / rural)

D. Agua, saneamiento e higiene — WASH (10)

Código	Variable
HV204	Tiempo de viaje a la fuente de agua
HV225	Comparte servicio higiénico
HV234	Prueba de yodo en la sal
HV237	Tratamiento del agua
HV237A	Tratamiento del agua: hervir
HV237G	Consumo de agua embotellada
SH42	Disponibilidad de agua todo el día
SH48	Conserva agua
SH49 / SH50	Tipo de recipiente y si lo usa con tapa

E. Vivienda y entorno (11)

Código	Variable
`HV040`	Altitud del conglomerado (msnm)
`HV216`	Habitaciones para dormir
`SH71`	Número de habitaciones del hogar
`HV240`	Tiene chimenea o campana
`HV242`	Cuarto separado para cocinar
`SH63`	Otro tipo de combustible para cocinar
`SH70`	Fuente de luz
`SH76B` / `SH76C` / `SH76D`	Ventanas con cristal / de madera / con malla
`SH77F`	Otro tipo de transporte

> **Nota:** el conjunto es ampliable. El *dataset* original contiene más de 180 variables, de las cuales se retuvieron 45 por criterios estadísticos. Si los especialistas consideran relevante alguna dimensión no cubierta —consumo dietético, morbilidad reciente, vacunación, antropometría materna— puede incorporarse siempre que exista en la fuente de datos.

4. Especificación de campos

Esta tabla define **cómo debe venir codificada cada variable** en un conjunto de datos externo. El modelo compara valores de forma literal: una categoría escrita de otra manera (`"URBANO"` en lugar de `"Urbano"`, o `1/0` en lugar de `"Si"/"No"`) no produce un error visible, sino una predicción degradada en silencio. Por eso el formato importa tanto como la variable misma.

Convenciones - *Categórica nominal*: texto, exactamente uno de los valores listados. No hay orden entre ellos. - *Categórica ordinal*: texto, con orden implícito (de mayor a menor, según se lista). - *Binaria*: texto, `Sí` o `No`. - *Numérica*: magnitud real, en la unidad indicada. Aquí el número **sí** representa una cantidad. - Un campo ausente debe dejarse **vacío**, nunca rellenarse con 0, 999 o “NA”: el modelo maneja valores faltantes de forma nativa y cada variable tolera el porcentaje de vacíos que se indica.

Las categorías se entregan **en texto, no en código numérico**. El `1` de una variable nominal no es una cantidad sino una etiqueta arbitraria, y su significado cambia entre ediciones de la encuesta: es preferible escribir `Electricidad` antes que `1`. Si el sistema de origen almacena códigos, basta con adjuntar su diccionario de valores.

Niño

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`HC1`	Numérica	0 – 59	meses	0.0

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HC27	Categórica nominal	Hombre / Mujer	sexo del niño	0.0
HC56	Numérica	4 – 20 (hemoglobina ajustada)	g/dL	9.6
HC63	Numérica	7 – 388	meses desde el parto anterior	36.3

Salud materna, embarazo y lactancia

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
M13	Numérica	0 – 9	mes de gestación del 1.er control	19.7
M14	Numérica	0 – 20	número de visitas	18.6
m15	Categórica nominal	Institucional / Domiciliario	lugar del parto	6.6
M17	Binaria	Sí / No	¿el parto fue por cesárea?	5.8
M18	Categórica ordinal	Muy grande / Grande / Mediano (normal) / Pequeño / Muy pequeño	tamaño percibido al nacer	5.8
m19	Numérica	0.5 – 6.0	kilogramos (decimal)	10.6
M4	Numérica	0 – 59	meses de lactancia	5.8
m34	Numérica	0 – 2352	horas hasta iniciar lactancia	6.2
M46	Numérica	0 – 364	días que tomó hierro	18.7
M54	Binaria	Sí / No	vitamina A en los 2 meses post parto	19.7
M55G	Binaria	Sí / No	fórmula en los 3 primeros días	6.8

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
M60	Binaria	Sí / No	antiparasitarios durante el embarazo	19.9
HC62	Numérica	0 – 9	años de educación aprobados por la madre	4.8

Hogar y nivel socioeconómico

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV271	Numérica	−215987 a 205316	índice de riqueza (escala INEI $\times 10^5$)	0.8
HV012	Numérica	0 – 25	personas	0.0
HV014	Numérica	0 – 10	niños menores de 5 años en el hogar	0.0
HV219	Categórica nominal	Masculino / Femenino	sexo del jefe del hogar	0.0
HV220	Numérica	12 – 97	años	0.0
HV102	Binaria	Sí / No	residente habitual del hogar	2.4
HV025	Categórica nominal	Urbano / Rural	área de residencia	0.0

Agua, saneamiento e higiene (WASH)

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV204	Numérica	0 – 600	minutos hasta la fuente	0.1
HV225	Binaria	Sí / No	¿comparte servicio higiénico?	10.8
HV234	Numérica	0, 7, 15, 30	yodo en sal (ppm por colorimetría)	4.8
HV237	Binaria	Sí / No	¿trata el agua?	0.0

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV237A	Binaria	Sí / No	¿hierve el agua?	0.0
HV237G	Binaria	Sí / No	¿consume agua embotellada?	8.1
SH42	Binaria	Sí / No	¿dispone de agua todo el día?	20.4
SH48	Binaria	Sí / No	¿conserva agua?	15.8
SH49	Categórica nominal	Olla, tetera / Balde / Jarra / Bidón / Otro	recipiente donde conserva el agua	20.4
SH50	Binaria	Sí / No	¿usa el recipiente con tapa?	19.3

Vivienda y entorno

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
HV040	Numérica	0 – 5053	metros sobre el nivel del mar	0.0
HV216	Numérica	0 – 14	habitaciones para dormir	0.0
HV240	Categórica nominal	Ni chimenea ni campana / Tubo de lámpara / Capucha	extracción de humo en la cocina	55.9
HV242	Binaria	Sí / No	¿cuarto separado para cocinar?	9.3
SH63	Binaria	Sí / No	¿usa otro combustible para cocinar?	2.1
SH70	Categórica nominal	Electricidad / GLP / Gas natural / Kerosene / Velas / Batería / Otro	tipo de alumbrado	1.6

Código	Tipo	Valores admitidos	Unidad	% nulos tolerado
`SH71`	Numérica	1 – 30	habitaciones del hogar	0.0
`SH76B`	Binaria	`Sí` / `No`	ventanas con cristal	16.2
`SH76C`	Binaria	`Sí` / `No`	ventanas de madera	16.2
`SH76D`	Binaria	`Sí` / `No`	ventanas con malla	16.2
`SH77F`	Binaria	`Sí` / `No`	otro tipo de transporte	0.0

> **Advertencia sobre la codificación heredada.** Las tres irregularidades que siguen provienen de la propia ENDES y se conservaron para no alterar la fuente; se señalan aquí porque condicionan el formato de entrega:
>
> 1. **`Si` frente a `Sí`.** Internamente unas variables llevan tilde y otras no, según el módulo de origen. Para la entrega esto es indiferente: basta escribir `Sí` de forma uniforme.
> 2. **Binarias en dos formatos internos.** `M17`, `M54`, `M55G` y `M60` viajan como `1`/`0` dentro del sistema, mientras que el resto de las dicotómicas usan texto. Para la entrega basta con `Sí`/`No` en todas: la homologación corre por cuenta del equipo.
> 3. **Códigos especiales.** Internamente `SH49` y `SH70` reservan 96, 98 y 99 para *otro* y *no sabe*. Al entregarse como texto esto deja de ser un problema: escriba `Otro` cuando corresponda y deje la celda **vacía** cuando el dato no se pudo obtener.
>
> Si el conjunto de datos externo emplea otra codificación, basta con entregarlo acompañado de su diccionario de valores: el equipo se encarga de la homologación.

5. Variables adicionales deseables

Las 45 variables anteriores son las que el modelo **usa hoy** y constituyen el mínimo necesario para contrastarlo. Las que siguen **no están en el modelo actual** y se solicitan porque la literatura epidemiológica las identifica como determinantes de la desnutrición crónica que la ENDES no permite cubrir con suficiente completitud.

Su inclusión es **opcional**: el sistema funciona sin ellas. Pero cada dimensión que el conjunto de datos externo pueda aportar abre la posibilidad de una versión mejorada del modelo, y su ausencia es hoy una limitación declarada del estudio.

El marco de referencia es el **modelo conceptual de UNICEF** sobre desnutrición infantil, que ordena las causas en tres niveles y que la serie de nutrición materno-infantil de *The Lancet* sistematiza (Black et al., 2013; Victora et al., 2021). El modelo actual cubre bien los niveles básico y subyacente —pobreza, educación, agua y saneamiento, vivienda— pero tiene un vacío en el **nivel inmediato**, que es precisamente donde actúa la intervención nutricional.

Prioridad alta — nivel inmediato (el vacío principal)

Dimensión	Campo sugerido	Por qué importa
Morbilidad reciente	Episodios de diarrea en las últimas 2 semanas (sí/no)	Vía infecciosa hacia la malabsorción de nutrientes
Morbilidad reciente	Infección respiratoria aguda en las últimas 2 semanas (sí/no)	Impacto directo sobre el estado nutricional
Ingesta	Diversidad dietética mínima (número de grupos de alimentos en 24 h)	Indicador OMS de calidad de la alimentación
Ingesta	Frecuencia mínima de comidas según edad	Complemento del anterior
Suplementación	Recibe micronutrientes o hierro (sí/no, frecuencia)	Intervención directa y modificable

Prioridad media — estado nutricional materno y servicios

Dimensión	Campo sugerido	Por qué importa
Antropometría materna	Talla de la madre (cm)	Predictor consistente de retraso del crecimiento intergeneracional; resultó la variable más influyente en un modelo equivalente sobre datos DHS (Ndagijimana et al., 2025)
Antropometría materna	Peso / IMC de la madre	Estado nutricional del hogar
Servicios de salud	Controles CRED al día (sí/no, número)	Seguimiento del crecimiento en el sistema peruano
Servicios de salud	Esquema de vacunación completo para la edad (sí/no)	*Proxy* de acceso efectivo a servicios

Prioridad media — contexto social

Dimensión	Campo sugerido	Por qué importa
Etnicidad	Lengua materna de la madre	Marcador de exclusión estructural especialmente relevante en el Perú
Seguridad alimentaria	Escala de inseguridad alimentaria del hogar (ELCSA o similar)	Acceso efectivo a alimentos, no solo capacidad económica
Cuidado	Situación laboral de la madre / cuidador principal	Tiempo disponible para prácticas de cuidado

Dimensión	Campo sugerido	Por qué importa
Programas sociales	Beneficiario de Juntos, Cuna Más, Qali Warma (sí/no)	Permite evaluar cobertura frente a necesidad

> **Sobre el formato.** Estas variables no requieren la codificación estricta de la sección 4, ya que aún no forman parte del modelo. Basta con entregarlas tal como estén registradas, acompañadas de su diccionario de valores. El equipo se encarga de homologarlas.

> **Una aclaración necesaria.** Las variables de morbilidad reciente (diarrea, IRA) son causas inmediatas, pero también son *concurrentes* con el desenlace: si un agente de salud ya sabe que el niño tuvo diarrea, es porque hubo contacto previo con el sistema. Por eso se solicitan para **análisis explicativo** y para una eventual versión del modelo orientada a seguimiento, no necesariamente para el triaje anticipado, cuyo valor reside justamente en operar sin visita previa.

---

6. Qué esperamos de esta validación

Solicitamos la participación de **cinco especialistas** en nutrición, salud pública, epidemiología o enfermería, idealmente con representación territorial (**2 de costa, 2 de sierra, 1 de selva**), para dos procesos complementarios:

6.1 Pertinencia

Valoración de la **utilidad percibida** del sistema mediante un instrumento estructurado que el especialista completará tras una demostración del aplicativo. Se evalúa si la herramienta resulta útil, comprensible y aplicable en la práctica real de focalización sanitaria, y qué limitaciones o variables faltantes identifica desde su experiencia profesional.

Modalidad: sesión virtual, coordinada según disponibilidad. El equipo provee el protocolo, conduce la demostración y registra la sesión.

6.2 Replicabilidad

Contraste del modelo frente a **datos externos** distintos de la ENDES. El procedimiento consiste en que el especialista aporte registros de su ámbito —incluyendo casos con y sin desnutrición diagnosticada—, el sistema emita su estimación de riesgo, y se compare con el diagnóstico clínico conocido.

Esto permite medir si el modelo mantiene su desempeño en una realidad distinta de aquella con la que fue entrenado. Se requieren **datos crudos** (no reportes agregados), con las variables listadas en la sección 3.

---

7. Consideraciones éticas

Los datos con los que se construyó el modelo son de **acceso público y libre** (portal de microdatos del INEI), por lo que su tratamiento no requirió aprobación de comité de ética.

Para la fase de validación con datos institucionales, el equipo se compromete a tramitar los permisos formales correspondientes y a someter el protocolo a comité de ética cuando la institución lo exija. Los datos que se reciban se usarán exclusivamente con fines de validación técnica, de forma anonimizada, y no serán publicados ni compartidos con terceros.

---

8. Contribución esperada para los participantes

Los especialistas que participen serán reconocidos en el artículo científico resultante. Asimismo, el equipo queda disponible para integrarse como soporte técnico en investigaciones posteriores que deseen aplicar el modelo en estudios de campo, intervención o gestión sanitaria.

Contacto: equipo de investigación — EP Ingeniería de Sistemas, Universidad Peruana Unión.

Referencias citadas

- Black, R. E., Victora, C. G., Walker, S. P., *et al*. (2013). Maternal and child undernutrition and overweight in low-income and middle-income countries. *The Lancet*, 382(9890), 427–451.
- Kaufman, S., Rosset, S., & Perlich, C. (2011). Leakage in data mining: formulation, detection, and avoidance. *Proceedings of the 17th ACM SIGKDD*, 556–563.
- Ndagijimana, S., Kabano, I., Masabo, E., & Ntaganda, J. M. (2025). Predicting stunting status among under-5 children in Rwanda using neural network model. *F1000Research*, 13, 128.
- Victora, C. G., Christian, P., Vidaletti, L. P., *et al*. (2021). Revisiting maternal and child undernutrition in low-income and middle-income countries. *The Lancet*, 397(10282), 1388–1399.