

¿Qué lograremos al finalizar esta sesión?

Al finalizar la sesión, el estudiante evaluará críticamente los resultados de su investigación científica que realizó en ciclo anterior, a través de la aplicación de criterios de validez, confiabilidad y técnicas de evaluación reconocidas internacionalmente (ISO/IEC 25010, CASP, JBI, SUS, Delphi), con el fin de fortalecer la calidad metodológica de su futuro artículo científico.

VERBO

Evaluará críticamente

OBJETO

Los resultados de investigaciones científicas en Ingeniería de Sistemas (considera su proyecto de investigación)

CONDICIÓN

Aplicando criterios de validez, confiabilidad y estándares internacionales (ISO/IEC 25010, CASP, JBI, SUS, entre otros)

¿Confiamos demasiado en lo que leemos?

70%

de los investigadores encuestados intentó reproducir el experimento de OTRO científico... y fracasó.

50%+

no logró reproducir ni siquiera sus PROPIOS experimentos anteriores.

Fuente: Baker, M. (2016). 1,500 scientists lift the lid on reproducibility. Nature, 533(7604), 452-454.

Véase también: Ioannidis, J. P. A. (2005). Why most published research findings are false. PLoS Medicine, 2(8), e124.

Caso ilustrativo: el algoritmo que “mejoraba” un 40%

Caso compuesto a partir de patrones frecuentes documentados en la literatura de meta-investigación en Ciencias de la Computación.

- 1 Situación:** un equipo de desarrollo publica un artículo afirmando que su nuevo algoritmo de recomendación mejora la precisión en un 40% frente al estado del arte.
- 2 Hallazgo en la revisión por pares:** el conjunto de prueba era el mismo usado para entrenar el modelo (data leakage); no se reportaron intervalos de confianza; no hubo réplica en un segundo dataset independiente.
- 3 Desenlace:** el artículo fue rechazado por carecer de validez interna y confiabilidad suficientes en sus resultados.

Activemos tus saberes previos

M

“En una palabra, ¿qué significa para ti VALIDAR un resultado científico?”

Q1

¿Cuál de estos NO es un criterio de calidad de un resultado de investigación?

a) Validez b) Confiabilidad c) Popularidad en redes sociales d) Replicabilidad

Respuesta: c) Popularidad en redes sociales

Q2

La capacidad de un instrumento de producir resultados consistentes en mediciones repetidas se llama:

a) Validez b) Confiabilidad c) Objetividad d) Generalización

Respuesta: b) Confiabilidad

Q3

¿Qué estándar internacional evalúa la calidad de un producto de software?

a) APA 7ma ed. b) ISO/IEC 25010 c) COPE d) PRISMA

Respuesta: b) ISO/IEC 25010

Desarrollo teórico-práctico

18 bloques de contenido: de la definición de 'resultado' a los estándares que exige una revista Q3-Q1.

¿Qué es evaluar resultados de investigación?

- 1 **Definición:** proceso sistemático de examinar la calidad, coherencia y solidez de los hallazgos obtenidos en un estudio.
- 2 **No es solo comprobar 'si funcionó':** implica examinar CÓMO se obtuvo el resultado y si el proceso realmente sostiene la conclusión.
- 3 **Aplica a todo diseño metodológico:** estudios cuantitativos (experimentos, métricas) y cualitativos (percepciones, procesos).
- 4 **En Ingeniería de Sistemas:** incluye evaluar algoritmos, arquitecturas, modelos predictivos y la calidad de los datos empleados.
- 5 **Es el filtro previo indispensable** antes de redactar resultados para someterlos a revisión por pares.

Importancia de la evaluación rigurosa en IS

- 1 Evita publicaciones frágiles:** previene la difusión de hallazgos que terminan en retractaciones (retractions).
- 2 Fortalece la credibilidad:** del investigador y de la UPeU ante las bases de datos indexadas (Scopus, Web of Science).
- 3 Es requisito editorial explícito:** las revistas Q1-Q2 exigen una sección de 'Threats to Validity' o 'Limitations'.
- 4 Permite comparaciones justas:** frente al estado del arte al proponer nuevas soluciones tecnológicas.
- 5 Sostiene la toma de decisiones** en la industria TI, donde se adoptan tecnologías con base en evidencia publicada.

Resultados, hallazgos y conclusiones no son sinónimos

Confundir estos tres niveles es uno de los errores más frecuentes en artículos rechazados por revistas indexadas.



Criterios de validez interna

- 1 Definición:** grado en que el diseño garantiza que los cambios observados se deben a la variable estudiada y no a factores externos.
- 2 Amenazas clásicas:** historia, maduración, selección de la muestra, mortalidad experimental, instrumentación.
- 3 En estudios de software:** contaminación de datos (data leakage), ausencia de grupo de control, condiciones de prueba no controladas.
- 4 Pregunta guía:** '¿los resultados obtenidos se deben realmente a lo que el estudio dice haber probado?'

Criterios de validez externa

- 1 **Definición:** grado en que los resultados pueden generalizarse a otros contextos, poblaciones, sistemas o conjuntos de datos.
- 2 **En Ingeniería de Sistemas:** ¿el algoritmo rinde igual en otro dataset? ¿la arquitectura escala en un entorno de producción real?
- 3 **Amenazas frecuentes:** muestra no representativa, entorno artificial de laboratorio, sesgo propio del dataset utilizado.
- 4 **Buenas prácticas:** validación cruzada (cross-validation), pruebas en múltiples datasets o entornos, réplica independiente.

Confiabilidad (reliability): principales tipos


Tipo de confiabilidad	¿Qué evalúa?	Ejemplo en Ingeniería de Sistemas
Test-retest	Consistencia al repetir la medición en el tiempo	Repetir un benchmark de rendimiento en distintas fechas
Inter-evaluador	Consistencia entre distintos observadores o jueces	Dos revisores califican la usabilidad con el mismo instrumento
Consistencia interna (α de Cronbach)	Coherencia entre los ítems de un instrumento	Encuesta de aceptación tecnológica (TAM) aplicada a usuarios
Confiabilidad del sistema	Estabilidad del comportamiento ante entradas similares	Determinismo de un algoritmo bajo las mismas condiciones de entrada

Validez de constructo


- 1 **Definición:** grado en que un instrumento o métrica realmente mide el concepto teórico que dice medir.
- 2 **Ejemplo cuestionado en IS:** ¿'líneas de código' mide realmente la 'complejidad del software'? Es un debate abierto en la literatura.
- 3 **Formas de evaluarla:** análisis factorial, juicio de expertos, correlación con métricas ya validadas previamente.
- 4 **Relación directa** con la operacionalización de variables durante el diseño metodológico del estudio.

La relación entre validez y confiabilidad


Un instrumento puede ser confiable sin ser válido; rara vez es válido sin ser, al menos, razonablemente confiable.




**Alta validez
Alta confiabilidad**



**Baja validez
Alta confiabilidad**



**Alta validez
Baja confiabilidad**



**Baja validez
Baja confiabilidad**

Técnicas cuantitativas de evaluación de resultados

Técnica / métrica	¿Qué aporta?	Uso típico en Ingeniería de Sistemas
Valor p (p-value)	Probabilidad de observar el resultado si la hipótesis nula fuera cierta	Comparar el rendimiento de dos algoritmos
Tamaño del efecto (Cohen's d)	Magnitud práctica de la diferencia, más allá de la significancia	Evaluar si una mejora es relevante en la práctica
Intervalo de confianza (IC 95%)	Rango plausible para el parámetro poblacional estimado	Reportar la precisión de una métrica de accuracy
Precisión, Recall, F1-score, AUC-ROC	Calidad de modelos predictivos y clasificadores	Evaluación de modelos de machine learning

Evaluación en Ingeniería de Software: rendimiento y benchmarking

- 1 **Benchmarking:** comparación sistemática de un sistema o algoritmo contra líneas base reconocidas, usando datasets estándar del dominio.
- 2 **Métricas de rendimiento:** tiempo de ejecución, uso de memoria, throughput, latencia, escalabilidad.
- 3 **Reproducibilidad del entorno:** reportar hardware, software y configuración completos usados en el experimento.
- 4 **Comparar con rigor estadístico:** pruebas como Wilcoxon o ANOVA, no solo el promedio bruto entre algoritmos.

Estándar ISO/IEC 25010 para evaluar sistemas de software

Marco de referencia obligado al evaluar resultados de estudios que proponen o valoran sistemas de software.

ISO/IEC 25010 — Modelo de calidad de producto de software y sistemas

1

Adecuación funcional

Cobertura y corrección de las funciones implementadas

2

Eficiencia de desempeño

Comportamiento en tiempo, uso de recursos y capacidad

3

Compatibilidad

Coexistencia con otros sistemas e interoperabilidad

4

Usabilidad

Facilidad de uso, aprendizaje y accesibilidad

5

Confiabilidad (reliability)

Madurez, disponibilidad, tolerancia a fallos

6

Seguridad

Confidencialidad, integridad y trazabilidad de la información

7

Mantenibilidad

Modularidad, reusabilidad y capacidad de prueba

8

Portabilidad

Adaptabilidad, instalabilidad y capacidad de reemplazo

Errores comunes al evaluar resultados

- 1 **P-hacking:** manipular el análisis –probando múltiples pruebas– hasta obtener un p-valor ‘significativo’.
- 2 **HARKing:** presentar una hipótesis formulada DESPUÉS de conocer los resultados como si hubiese sido planteada a priori.
- 3 **Sobregeneralización:** extender conclusiones más allá de lo que el diseño y la muestra realmente permiten.
- 4 **Sesgo de confirmación:** interpretar los resultados de forma que confirmen la hipótesis deseada, ignorando evidencia contraria.

Evaluación de resultados y publicación en revistas indexadas

- 1 **Los revisores evalúan primero el rigor:** la validez y confiabilidad se revisan antes que la 'novedad' del tema.
- 2 **Sección obligatoria:** 'Threats to Validity' / 'Limitations' en la mayoría de revistas de Ingeniería de Software indexadas.
- 3 **Menor riesgo de rechazo:** una autoevaluación rigurosa reduce la probabilidad de 'reject' o 'major revision' por debilidad metodológica.
- 4 **A mayor cuartil, mayor exigencia:** las revistas Q1 piden más rigor en la evaluación de resultados que las de menor impacto.

Informe de evaluación crítica vinculado a tu proyecto de tesis en función de sus resultados

OBJETIVO

Elaborar, en equipo, un informe de evaluación crítica que aplique los criterios trabajados en la sesión sobre los resultados de tu proyecto de tesis indica que abordaste de manera objetiva, que esta faltando y como vas abordar lo que esta faltando considerando que los tiempos son limitados.

ENTREGABLE

Informe PDF, 2-4 páginas,— aula virtual UPeU, carpeta 'Sesión 01 - CREA'

PLAZO

Antes del inicio de la Sesión 02 (una semana)