

## INFORME DE EVALUACIÓN CRÍTICA DE RESULTADOS

**Proyecto:** Sistema Predictivo de Riesgo de Desnutrición Crónica Infantil en el Perú mediante Machine Learning (ENDES 2007–2024)

**Curso:** Investigación V (Ciclo X – 2026-II) | **Docente:** Mg. Nemias Saboya Rios

**Equipo de Trabajo:** Abel Guevara Huasco, Verónica Vergara Rojas, Pamela Vallejos Cotrina

### 1. INTRODUCCIÓN Y CONTEXTUALIZACIÓN DE LOS RESULTADOS

El presente informe realiza una evaluación crítica y rigurosa de los resultados obtenidos en el proyecto de tesis durante el ciclo anterior, aplicando los criterios de validez interna, validez externa y confiabilidad/calidad del software trabajados en la Sesión 01.

| Métrica               | Valor Baseline  | Interpretación y Significado Clínico / Político                             |
|-----------------------|-----------------|-----------------------------------------------------------------------------|
| AUC-ROC               | 0.8308          | Capacidad discriminativa global del 83% entre niños sanos y desnutridos.    |
| Recall (Sensibilidad) | 76.49%          | Detecta a 3 de cada 4 niños desnutridos (34,400 de 45,000 en la muestra).   |
| Precision             | 37.05%          | 1 de cada 3 alertas de alto riesgo corresponde a un caso real confirmado.   |
| F1-Score              | 0.4976          | Balance armónico entre la cobertura de detección y la precisión.            |
| Umbral de Producción  | 0.50 (Fijo)     | Umbral por defecto, no optimizado previamente (deuda técnica).              |
| Explicabilidad SHAP   | Top 3 variables | Índice de riqueza del hogar (HV271), Peso al nacer (m19) y Altitud (HV040). |

### 2. EVALUACIÓN CRÍTICA DE LA VALIDEZ INTERNA

La validez interna evalúa si las predicciones se deben strictly al diseño metodológico y a las variables independientes, garantizando la ausencia de sesgos técnicos o artefactos.

| Aspecto Evaluado                    | Estado Actual          | Análisis Crítico y Evidencia Técnica                                                                                                                                             |
|-------------------------------------|------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Validación Cruzada 5-Fold con Pesos | Abordado Concretamente | Se incorporó el factor de expansión muestral INEI (HV005 / 1,000,000), evitando el sesgo de sobre-representación urbana y preservando la prevalencia del 16% en cada fold.       |
| Selección Algorítmica de Variables  | Abordado Concretamente | Filtrado por importancia nativa (feature_importances_ $\geq$ 10), reduciendo de 74 a 43 variables. El modelo superó al original en AUC (0.830779 vs 0.830680), eliminando ruido. |
| Descarte del Accuracy               | Abordado Concretamente | Se prohibió el uso de Accuracy debido al desbalance de clases (16% desnutridos / 84% sanos), el cual habría sobreestimado el rendimiento prediciendo solo la clase mayoritaria.  |
| Suboptimización del Umbral          | Parcialmente Abordado  | El umbral fijo 0.50 limita el Recall a 76.49% (meta $\geq$ 80%), dejando fuera al 23.5% de niños desnutridos. Bajar el umbral a $\sim$ 0.35 corregiría esta brecha.              |
| Significancia Estadística (IC 95%)  | No Abordado / Brecha   | Los resultados se presentan como valores puntuales. Falta calcular Intervalos de Confianza al 95% mediante Bootstrap y realizar el Test de DeLong entre modelos.                 |

### 3. EVALUACIÓN CRÍTICA DE LA VALIDEZ EXTERNA

La validez externa analiza la generalización de los hallazgos a otros periodos temporales, geografías o sistemas reales de salud pública.

| Aspecto Evaluado                    | Estado Actual          | Análisis Crítico y Evidencia Técnica                                                                                                                                                          |
|-------------------------------------|------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Explicabilidad Territorial SHAP     | Abordado Concretamente | Validación sobre 285,284 registros representativos de 25 departamentos. Se demostró la variación del riesgo por región (Costa: Riqueza; Sierra: Altitud y Hemoglobina; Selva: Peso al nacer). |
| Sensibilidad al Target Drift        | Parcialmente Abordado  | La prevalencia nacional cayó del 30% (2007) al 11% (2024). Aunque el 5-Fold CV incluyó muestras de todos los años, no se evaluó la degradación temporal separada por épocas.                  |
| Validación Out-of-Time (OOT)        | No Abordado / Brecha   | Ausencia de un split temporal estricto (ej. entrenar en 2007–2021 y evaluar prospectivamente en 2022–2024), paso indispensable para certificar resiliencia operacional.                       |
| Generalización en Datasets Externos | No Abordado / Brecha   | Dependencia total de la estructura SPSS de la ENDES. No se ha probado en registros administrativos de establecimientos de salud (MINSa/HIS) o padrones municipales.                           |

### 4. CONFIABILIDAD Y CALIDAD DEL SISTEMA (ISO/IEC 25010)

La confiabilidad evalúa la consistencia de las mediciones y la calidad técnica del software según la norma internacional ISO/IEC 25010.

| Aspecto Evaluado               | Estado Actual          | Análisis Crítico y Evidencia Técnica                                                                                                 |
|--------------------------------|------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| Replicabilidad del Pipeline    | Abordado Concretamente | Repositorio estructurado en Python con semillas fijas (random_state=42), permitiendo reproducir exactamente cada métrica reportada.  |
| Prototipo Funcional Streamlit  | Abordado Concretamente | Aplicación web interactiva desarrollada en Streamlit + Plotly, con respuesta en menos de 1 segundo por predicción individual.        |
| Control Dinámico de Umbral     | Parcialmente Abordado  | La app permite simular visualmente la cobertura deseada (ej. 80% Recall), pero no persiste sesiones ni genera reportes descargables. |
| Evaluación de Usabilidad (SUS) | No Abordado / Brecha   | No se ha aplicado el cuestionario estandarizado SUS (System Usability Scale) con personal sanitario en campo.                        |

### 5. MATRIZ RESUMEN DE EVALUACIÓN CRÍTICA

| Dimensión        | Aspecto Evaluado                 | Estado Actual          | Evidencia / Brecha Identificada                        |
|------------------|----------------------------------|------------------------|--------------------------------------------------------|
| Validez Interna  | 5-Fold CV con Pesos (HV005)      | Abordado Concretamente | Ponderación muestral y estratificación 5 folds.        |
| Validez Interna  | Selección Vars (43 cols)         | Abordado Concretamente | Filtrado importances >= 10 superó a 74 vars.           |
| Validez Interna  | Optimización de Umbral           | Parcialmente Abordado  | Umbral fijo 0.50; ajustar a ~0.35 para Recall >= 80%.  |
| Validez Interna  | Intervalos de Confianza (IC 95%) | No Abordado / Brecha   | Falta Bootstrap (95% IC) y test DeLong.                |
| Validez Externa  | Explicabilidad SHAP Regional     | Abordado Concretamente | SHAP beeswarm y heatmaps 25 dptos.                     |
| Validez Externa  | Validación Temporal OOT          | No Abordado / Brecha   | Falta split OOT: Train 2007–2021 / Test 2022–2024.     |
| Confiabilidad    | Replicabilidad Pipeline          | Abordado Concretamente | Pipeline modular con random_state=42.                  |
| Calidad Software | Evaluación Usabilidad (SUS)      | No Abordado / Brecha   | Cuestionario SUS pendiente de aplicación a operadores. |

6. PLAN DE ACCIÓN PRIORIZADO Y MATRIZ DE ABORDAJE

Considerando la carga académica del semestre (5 asignaturas adicionales) y los compromisos laborales de prácticas pre-profesionales del equipo, se presenta la matriz de planificación ejecutiva distribuida gradualmente a lo largo del semestre:

| N.º | Brecha Identificada                                    | Acción Correctiva Propuesta                                                                                                       | Recursos y Método                             | Resultado Esperado                                           | Plazo Distribuido                  |
|-----|--------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------|--------------------------------------------------------------|------------------------------------|
| 1   | Umbral 0.50 deja el Recall en 76.49% (meta >= 80%).    | <b>Threshold Tuning:</b> Barrido Grid del umbral de 0.10 a 0.50 en 5 folds para seleccionar el corte que garantice Recall >= 80%. | Python (scikit-learn), Precision-Recall Curve | Recall >= 80.0%, Umbral óptimo ~0.35 en producción.          | Semanas 2 – 3 (Trabajo inicial)    |
| 2   | Falta de intervalos de confianza (95% IC) y p-values.  | <b>Cálculo de IC al 95%:</b> Muestreo Bootstrap (1,000 iteraciones) sobre el test fold para AUC y Recall.                         | Python (scipy.stats, numpy bootstrap)         | Tablas formalizadas AUC/Recall [IC 95%] para manuscrito.     | Semanas 4 – 5 (Previo a parciales) |
| 3   | Ausencia de validación ante el Target Drift histórico. | <b>Validación Temporal Out-of-Time (OOT):</b> Re-entrenar LightGBM en 2007–2021 y evaluar prospectivamente en 2022–2024.          | Python, dataset ENDES separado por HV007      | Matriz de confusión OOT y curva ROC demostrando estabilidad. | Semanas 6 – 8 (Bloque medio)       |
| 4   | Ausencia de evaluación de usabilidad según ISO 25010.  | <b>Test de Usabilidad SUS:</b> Cuestionario System Usability Scale aplicado a 10 evaluadores en prototipo Streamlit.              | Cuestionario SUS (10 ítems), App Streamlit    | Score SUS > 75 pts (Nivel Acceptable) en informe final.      | Semanas 9 – 11 (Fase final)        |

COMPROMISO DE EJECUCIÓN TÉCNICA:

El plan permite balancear adecuadamente las exigencias laborales de prácticas pre-profesionales y la carga académica de las 5 asignaturas adicionales del ciclo. Las **Acciones 1 y 2** se ejecutarán durante la primera mitad del semestre por su carácter puramente computacional. Las **Acciones 3 y 4** se abordarán de forma gradual en la segunda mitad del ciclo.