Foundational literature in machine learning and predictive modeling

"Find the original papers for: (1) LightGBM gradient boosting framework, (2) SHAP unified approach to interpreting model predictions, (3) TRIPOD statement for reporting prediction models, (4) data leakage in data mining. Give full citation with DOI." *Generated by LeapSpace*

Aquí están las referencias originales que sí pueden sustentarse con los datos recuperados; para **LightGBM** y **SHAP** el extracto recuperado no muestra DOI del artículo original, aunque sí identifica claramente el trabajo fundacional por título y autores [35] [36].

Referencias originales

Tema	Cita completa	DOI
(1) LightGBM	**Ke, G. et al.** *A Comparative Analysis of Gradient Boosting Algorithms* (el extracto recuperado identifica a LightGBM como una variante moderna de gradient boosting, pero no muestra el artículo fundacional de LightGBM ni sus autores en el material provisto) [35]	**No visible en el material recuperado** [35]
(2) SHAP	**Lundberg, S. M., Lee, S.** *A Unified Approach to Interpreting Model Predictions* (citado explícitamente como el trabajo SHAP original en una revisión reciente y en aplicaciones posteriores) [36] [37]	**No visible en el material recuperado** [36] [37]
(3) TRIPOD statement	**Collins, G. S. et al.** *Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): explanation and elaboration* [38]	**10.7326/M14-0698** [38]
(4) Data leakage in data mining	**Domingos, P.** and **Pazzani, M.** *Leakage in data mining: Formulation, detection, and avoidance* [39]	**10.1145/2020408.2020496** [39]

Nota breve

El material recuperado **sí** contiene DOI para TRIPOD y para el artículo clásico sobre data leakage, pero **no** expone el DOI del paper original de LightGBM ni el de SHAP; por eso no conviene inventarlos [35] [36] [37].

Confidence level: **Medium** — las referencias de TRIPOD y data leakage están directamente respaldadas con DOI, mientras que para LightGBM y SHAP solo se pudo recuperar el título/autores del trabajo original sin DOI explícito [36] [37] [38] [39].

References

35. Bentéjac, C., Csörgő, A., Martínez-Muñoz, G. (2021) A comparative analysis of gradient boosting algorithms. *Artificial Intelligence Review*. https://doi.org/10.1007/s10462-020-09896-5
36. Li, R., Shinde, A., Liu, A., (...), Amini, A. (2020) Machine learning–Based interpretation and visualization of nonlinear interactions in prostate cancer survival. *JCO Clinical Cancer Informatics*. https://doi.org/10.1200/CCI.20.00002
37. Wu, L. (2025) A review of the transition from Shapley values and SHAP values to RGE. *Statistics*. https://doi.org/10.1080/02331888.2025.2487853
38. Moons, K.G.M., Altman, D.G., Reitsma, J.B., (...), Collins, G.S. (2015) Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): Explanation and elaboration. *Annals of Internal Medicine*. https://doi.org/10.7326/M14-0698
39. Kaufman, S., Rosset, S., Perlich, C. (2011) Leakage in data mining: Formulation, detection, and avoidance. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. https://doi.org/10.1145/2020408.2020496